Pengembangan Model Text Aduan telyu fess Terhadap Bagian penunjang Akademik Menggunakan Prompt Engineering

Development Complaint Text Model For Academic Support Departments Using Prompt Engineering

Proposal Tugas Akhir
Mata Kuliah BBK4AAB2

Disusun oleh:
SHAQUILLE RAYHANNIZAM WIBISONO
1204220136

PROGRAM STUDI SARJANA SISTEM INFORMASI
DIREKTORAT KAMPUS SURABAYA
UNIVERSITAS TELKOM
SURABAYA
2025

LEMBAR PENGESAHAN

PROPOSAL TUGAS AKHIR

JUDUL DALAM BAHASA INDONESIA

Proposal ini diajukan sebagai usulan pembuatan Tugas Akhir pada
Program Studi Sarjana Sistem Informasi
Direktorat Kampus Surabaya
Universitas Telkom

Disusun oleh:
SHAQUILLE RAYHANNIZAM WIBISONO
1204220136

Surabaya, ……
Menyetujui,

1. **Dr. Berlian Rahmy Lidiawaty, S.ST., M.MT.** (Pembimbing I)
   NIP. 22940041
2. **Agus Sulistya, Ph.D., M.MT.** (Pembimbing II)
   NIP. 19750005
3. **<Nama dan Gelar Penguji 1>** (Penguji I)
   NIP. XXXXXXXX
4. **<Nama dan Gelar Penguji II>** (Penguji II)
   NIP. XXXXXXXX

Kaprodi Sistem Informasi

Dr. Berlian Rahmy Lidiawaty, S.ST., M.MT.
NIP. 22940041

Pembimbing I,	**Pembimbing II**,
Dr. Berlian Rahmy Lidiawaty, S.ST., M.MT. NIP. 22940041	**Agus Sulistya, Ph.D., M.MT.** NIP. 19750005

Kaprodi Sistem Informasi

Dr. Berlian Rahmy Lidiawaty, S.ST., M.MT.
NIP. 22940041

LEMBAR PERNYATAAN ORISINALITAS

Nama	:	Shaquille Rayhannizam Wibisono
NIM	:	1204220136
Alamat	:	Jl. Terusan Bejo, Sisir, Kec. Batu, Kota Batu, Jawa Timur 65314 no.07
No. Telp	:	+6281233502636
Email	:	Shaquille.wibisono@gmail.com

Menyatakan bahwa Tugas Akhir ini merupakan karya orisinal saya sendiri. Atas pernyataan ini, saya siap menanggung risiko atau sanksi yang dijatuhkan kepada saya apabila kemudian ditemukan adanya pelanggaran terhadap kejujuran akademik atau etika keilmuan dalam karya ini, atau ditemukan bukti yang menunjukkan ketidakaslian karya ini.

Surabaya, ……
Shaquille Rayhannizam Wibisono

ABSTRAK

Seringkali aduan siswa yang disampaikan melalui survey kampus tidak dapat tersampaikan dikarenakan mahasiswa tidak ingin mengutarakan pendapat pribadi mereka dan justru malah diutarakan pada platform lain seperti pada media sosial, dikarenakan data yang dihasilkan melalui platform sosial media memiliki nilai strategis, karena dapat merepresentasikan persepsi dan tingkat kepuasan mahasiswa terhadap layanan universitas, pada penelitian ini digunakan data dari platform sosial media X Telyutfess untuk mendapatkan data teks aduan para mahasiswa, dataset tersebut akan digunakan dalam melakukan penelitian ini, Menggunakan metodologi Design Science Research Methodology (DSRM), penelitian dimulai dengan analisis kebutuhan melalui observasi literatur terkait penggunaan Large Language Model (LLM) dan klasifikasi teks aduan. Tujuan utama adalah mengembangkan model klasifikasi teks aduan berbasis LLM dengan teknik prompt engineering (few-shot prompting) untuk mengkategorikan aduan ke dalam tujuh label sesuai direktorat penunjang akademik Universitas Telkom Surabaya. Solusi meliputi konfigurasi prompt, pembuatan sistem sebagai artefak DSRM, serta evaluasi hasil klasifikasi menggunakan F1-score dan confusion matrix terhadap data ground truth yang telah divalidasi langsung oleh pihak direktorat terkait. Termasuk literatur yang membahas terkait klasifikasi teks aduan yang nantinya digunakan sebagai acuan dalam melakukan klasifikasi. Selanjutnya adalah menetapkan tujuan dan solusi, diawali dengan tujuan, yaitu menentukan teks aduan menggunakan metode klasifikasi, selanjutnya adalah menentukan solusi, yaitu dengan menetapkan tujuh label berdasarkan tujuh direktorat kampus berdasarkan data yang diambil dari media sosial X Telyufess, tahap solusi berikutnya adalah mengkonfigurasi prompt menggunakan *few shot prompting* sehingga LLM dapat mengklasifikasikan teks sesuai dengan tujuh kategori label yang sudah ditentukan. Tahap berikutnya adalah membuat sistem yang nantinya akan menjadi artefak pada metodologi DSRM, nantinya sistem akan menggunakan LLM dan Prompt engineering sebagai komponen utama dalam penelitian ini, luaran teks hasil klasifikasi nantinya akan di evaluasi menggunakan F1-score dan confusion matrix, menggunakan data *groundtruth* yang sudah dibuat sebelumnya, untuk memastikan keakuratan data groundtruth maka akan dilakukan validasi secara langsung kepada pihak direktorat terkait, tujuan akhir dari penelitian ini nantinya adalah untuk menyampaikan keluhan para mahasiswa yang tidak tersampaikan sebelumnya pada survey kampus, dengan menggunakan berupa model prompt untuk mengkategorikan aduan berbasis LLM dan prompt engineering. Hasil yang diharapkan dari penelitian ini nantinya adalah artefak yang berupa berupa model prompt untuk mengkategorikan aduan yang divisualisasi melalui web ui serta bersifat adaptif sehingga dapat digunakan pada kasus lain selain pada Telyufess.

Kata Kunci: *Klasifikasi Teks Aduan Dengan LLM,*

Commented [SR1]: List keyword yang digunakan tidak dijelaskan

ABSTRACT

Student complaints submitted through campus surveys often go unreported because students do not want to express their personal opinions and instead share them on other platforms such as social media. Data generated from social media platforms holds strategic value as it can represent students' perceptions and satisfaction levels with university services. In this study, data from the social media platform X Telyutfess is used to obtain textual complaint data from students. This dataset will be utilized for conducting the research. Using the Design Science Research Methodology (DSRM), the study begins with a requirements analysis conducted through a literature review on the use of Large Language Models (LLMs) and complaint text classification. The primary objective is to develop an LLM-based complaint text classification model using prompt engineering techniques (few-shot prompting) to categorize complaints into seven labels aligned with the supporting academic directorates of Telkom University Surabaya. The proposed solution includes prompt configuration, system development as a DSRM artifact, and evaluation of classification results using the F1-score and confusion matrix against ground truth data that have been directly validated by the relevant directorates. The next step is to determine the objectives and solutions, starting with the objectives, namely to classify complaint texts using a classification method, followed by determining the solution, which is by setting seven labels based on the seven campus directorates using data taken from the social media X Telyufess. The next stage of the solution is to configure prompts using few-shot prompting so that the LLM can classify texts according to the seven predetermined label categories. The next stage is to create a system that will later become an artifact in the DSRM methodology. The system will use LLM and prompt engineering as the main components of this research. The text output from the classification will be evaluated using F1-score and confusion matrix, using previously created ground truth data. To ensure the accuracy of the ground truth data, direct validation will be conducted with the relevant directorate. The ultimate goal of this research is to convey student complaints that were previously not captured by the campus survey, using a prompt model to categorize complaints based on LLM and prompt engineering. The expected outcome of this research is an artifact in the form of a prompt model for categorizing complaints, visualized through a web UI, and adaptive so that it can be applied to other cases beyond Telyufess.

.***Keywords:*** *Text Classification Method Using LLM*

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT, sehingga Tugas Akhir berjudul "Pengembangan Model Text Aduan telyu fess Terhadap Bagian penunjang Akademik Menggunakan Prompt Engineering" ini dapat selesai. Terima kasih kepada semua pihak yang telah mendukung dan membantu selama penyusunan laporan ini. Pertama dan utama, kepada Allah SWT yang senantiasa memberikan kekuatan, ketabahan, serta kemudahan dalam setiap langkah yang penulis jalani hingga tugas ini dapat terselesaikan. Penyusunan skripsi ini tentu tidak lepas dari bantuan dan dukungan berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan rasa terima kasih yang sebesar-besarnya kepada :

1. Kepada Ibu Dr. Berlian Rahmy Lidiawaty, S.ST., M.MT selaku dosen pembimbing I,
2. Bapak Agus Sulistya, Ph.D., M.MT. selaku dosen pembimbing II, Terima kasih atas waktu, bimbingan, masukan, dan dorongan semangat yang sangat berarti dalam membuat Proposal Tugas Akhir ini.
3. Rasa terima kasih yang tak terhingga penulis tujukan kepada kedua orang tua serta keluarga besar yang selalu menjadi sumber kekuatan, doa, dan semangat selama masa perkuliahan hingga tahap penyusunan tugas akhir.
4. Kepada rekan-rekan seperjuangan, yang selalu memberi dukungan moral dan motivasi selama masa studi.

Penulis menyadari bahwa tugas akhir ini masih memiliki banyak kekurangan karena keterbatasan ilmu dan pengalaman. Oleh karena itu, penulis memohon maaf atas segala ketidaksempurnaan yang ada. Semoga karya ini tetap dapat memberikan manfaat bagi para pembaca.

DAFTAR ISI

LEMBAR PENGESAHAN ..... **ii**
LEMBAR PERNYATAAN ORISINALITAS ..... **iv**
ABSTRAK ..... **v**
ABSTRACT ..... **vi**
KATA PENGANTAR ..... **vii**
DAFTAR ISI ..... **viii**
DAFTAR TABEL ..... **x**
DAFTAR GAMBAR ..... **xi**
DAFTAR LAMPIRAN ..... **xii**
DAFTAR ISTILAH ..... **xiii**
BAB I PENDAHULUAN **15**
1.1. Latar Belakang 15
1.2. Rumusan Masalah 17
1.3. Tujuan Penelitian 17
1.4. Batasan dan Asumsi Penelitian 17
1.5. Manfaat Penelitian 17
1.6. Sistematika Penulisan 18
BAB II LANDASAN TEORI **19**
2.1. Literatur Terkait Teori / Konsep Umum / Model / Kerangka Kerja 19
2.1.1. Library Python 25
2.1.2. NLP natural language processing 26
2.1.3. Transformer 26
2.1.4. LLM (large language model) 26
2.1.5. Prompt Engineering 26
2.1.6. Design Science Research Methodology 26
2.1.7. Crawling 27
2.1.8. Teks Processing 27
2.1.9. Evaluasi 27
2.2. Alasan Pemilihan Teori / Model / Kerangka Kerja 28
BAB III METODOLOGI PENELITIAN **31**
3.1 Sistematika Penyelesaian Masalah 31

3.2 Metodologi DSRM 32
3.2.1 Analisis Kebutuhan 32
3.2.2 Data Preparation 32
3.2.3 Rancangan Solusi Dari Masalah Dan Kebutuhan 34
3.2.4 Design & Development Proses 36
3.2.5 Testing dan demonstrasi sistem 42
3.3 Uji Validitas Dan Realibitas 47
3.3.1 Uji Validitas 47
3.3.2 Uji Realibilitas 47
3.4 Jadwal Kegiatan 47
DAFTAR PUSTAKA 54
LAMPIRAN 89

DAFTAR TABEL

Table 2.1.1 Literature Review 24
Table 2.1.2 Library Python 25
Table 2.2.1 Perbandingan LLM dengan Algoritma lain 29
Table 3.2.1 Confusion Matrix 40
Table 3.4.1 Rencana Kegiatan 47

DAFTAR GAMBAR

Gambar 3.2.1 Jumlah Data..... 33
Gambar 3.2.2 Alur Penyelesaian Permasalahan 34
Gambar 3.2.3 Alur Proses Klasifikasi..... 42
Gambar 3.2.4 Menu Klasifikasi Dataset 44
Gambar 3.2.5 Menu Prompt Manager 45
Gambar 3.2.6 Interface Evaluation 46

DAFTAR LAMPIRAN

DAFTAR ISTILAH

Artifact	:	(artefak) Istilah lain dari output yang dihasilkan melalui metode DSRM.
LLM	:	Largae Language Model (LLM) Adalah turunan AI yang merupakan sebuah model bahasa yang dibuat untuk meniru cara berfikir manusia dan menghasilkan output seidentik mungkin dengan bahasa manusia.
Prompt	:	Perintah berupa teks yang digunakan untuk memberikan oerintah kepada LLM.
Library	:	Dependensi yang bisa digunakan pada bahasa pemrograman python, berisikan kode python yang siap digunakan dengan cara mengimport dependensi tersbut langsung pada kode program.
Evaluation	:	Proses dalam metode DSRM untuk mengetahu tingkat ke akuratan output yang dihasilkan dari proses klasifikasi.
Crawling	:	Metode Pengambilan data secara otomasis menggunakan program.
Parameter	:	Konfigurasi yang digunakan dalam mengatur LLM seperti performa dan tingkat bias yang dihasilkan.
SOTA	:	(State of the Art) adalah istilah untuk menyebut metode, teknologi, atau model yang memiliki performa terbaik dan tercanggih pada saat tertentu.
NER	:	(Named Entity Recognition) adalah salah satu tugas dalam NLP yang bertujuan untuk mengidentifikasi dan mengklasifikasikan teks yang memiliki nama seperti, lokasi, nama orang, organisasi, dll.
RE	:	(Relation Extraction) adalah salah satu tugas dalam NLP yang bertujuan untuk menghubungkan entitas dengan tipe hubungan tertentu, seperti bekerja di, lahir di, bagian dari, dll.
Med-PaLM	:	adalah LLM yang dikhususkan pada bidang medis.
lesikon	:	suatu model yang berbasis kumpulan kata serta informasilinguistik terkait, digunakan dalam linguistik, NLP, dan psikolinguistik.
COT	:	(Chain Of Thought) adalah salahsatu metode dalam reasoning approach pada LLM di mana model diminta untuk menghasilkan urutan langkah berpikir yang eksplisit sebelum memberikan jawaban akhir.
ToT	:	(Tree of Thoughts) adalah suatu metode dalam reasoning approach untuk LLM yang memperluas pendekatan Chain of Thought (CoT) dengan menggunakan struktur seperti percabangan pada pohon untuk mengeksplorasi banyak kemingkinan pada bagaimana cara LLM berfikir.
PoT	:	(Program of Thoughts) adalah pendekatan reasoning paradigm untuk model LLM yang menggabungkan proses berpikir model dengan eksekusi program secara rinci. Pada pendekatan ini, LLM tidak hanya menghasilkan langkah-langkah penalaran dalam bentuk teks (seperti pada COT), tetapi menghasilkan program atau kode yang kemudian dieksekusi untuk memperoleh hasil yang akurat.

Self Consistency	:	metode yang digunakan untuk meningkatkan stabilitas hasil penalaran model dengan menghasilkan beberapa hasil menggunakan (CoT) secara independen, kemudian memilih jawaban akhir yang paling konsisten atau paling sering muncul.
DL-NLP	:	pendekatan dalam pemrosesan bahasa alami (NLP) yang menggunakan teknik deep learning
RL	:	metode yang digunakan untuk meningkatkan kemampuan LLM dengan belajar melalui mekanisme trial-and-error, memperoleh reward, dan sesuai dengan aturan yang diberikan untuk memaksimalkan output yang di hasilkan.
RLHF	:	(Reinforcement Learning from Human Feedback) adalah metode pelatihan LLM yang memanfaatkan feedback langsung melalui survey ataupun interaksi langsung dengan manusia untuk meningkatkan kualitas jawaban model melalui RL.
DPO	:	(Direct Preference Optimization) adalah metode pelatihan model bahasa yang bertujuan untuk membuat model dengan preferensi manusia secara langsung tanpa menggunakan algoritma RL.
REHAC	:	(Reinforcement Learning–based Heuristic Actor-Critic) Metode lain dari RL untuk meningkatkan efesiensi proses belajar LLM
RAG	:	(Retrieval-Augmented Generation) adalah metode dalam pemrosesan bahasa alami (NLP) yang menggabungkan antara LLM dengan pengambilan informasi dari sumber pengetahuan eksternal, dokumen dan website.
HippoRAG	:	(Hippocampal-Inspired Retrieval-Augmented Generation), hasil optimisasi dari RAG yang dapat menyimpan informasi lebih optimal dan dapat mengahsilkan jawaban yang lebih akurat.
LTSM	:	(Long Short-Term Memory), adalah jenis jaringan RNN yang dirancang khusus untuk mempelajari urutan data dan mengatasi masalah utama RNN biasa, perbedannya dengan RNN adalah LSTM mampu “mengingat” informasi penting dalam jangka panjang dan “melupakan” informasi yang tidak penting. Karena itu, LTSM sangat efektif untuk data berurutan.
Bi-LSTM	:	(Bidirectional Long Short-Term Memory) adalah jeni arsitektur RNN yang menggunakan dua LSTM sekaligus, yaitu membaca urutan data secara forward, dan backward, secara bersamaan, Tujuannya adalah agar model dapat memahami konteks masa lalu dan masa depan dalam sebuah sequence.

BAB I
PENDAHULUAN

1.1. Latar Belakang

Konsep seperti machine learning, deep learning, dan neural networks adalah hasil dari perkembangan teknologi dalam upaya meniru cara berpikir manusia, yang mengarah pada perkembangan *Artificial Intelligence* (AI) (Lin dkk., 2022). Kemunculan pertama dari *Large Language Model* (LLM) adalah salah satu hasil inovasi turunan AI. LLM sendiri adalah sistem *Natural Language Processing* (NLP) yang dapat menghasilkan teks kontekstual berdasarkan perintah pengguna. Salah satu jenis LLM adalah text generation, yaitu LLM yang dapat menghasilkan teks yang relevan ketika menerima perintah dari pengguna, seperti ChatGPT, deepseek, grok, dan lainnya (L. Chen dkk., 2020). Implementasi dari LLM sendiri memang dibuat sebagai alat yang dapat menjawab secara logis dan natural layaknya manusia. Sejumlah penelitian menunjukkan bahwa media sosial, masih menjadi platform yang digunakan oleh mahasiswa dalam menyampaikan pandangan, kritik, maupun dukungan terhadap aturan dan kebijakan kampus (Amiruzzaman & Amiruzzaman, 2022). Oleh sebab itu, data yang dihasilkan melalui platform sosial media memiliki nilai strategis, karena dapat merepresentasikan persepsi dan tingkat kepuasan mahasiswa terhadap layanan universitas (Fong Yee dkk., 2023). Pada studi kasus pada Telkom University, survey kepuasan kampus yang diberikan kepada mahasiswa terkadang tidak sesuai atau malah terkadang mahasiswa memberikan feedback sebaliknya dan jarang nya aduan mahasiswa yang disampaikan secara langsung dikarenakan proses nya yang cukup merepotkan membuat para mahasiswa tidak melaporkan permasalahan yang ada. oleh sebab itu dengan adanya penelitian ini diharapkan keluhan dan aduan terhadap kampus yang mahasiswa lampiaskan pada sosial media X telyufess dapat tersampaikan kepada pihak kampus, dimana kebanyakan mahasiswa Telkom University menggunakan platform telyufess untuk mengekspresikan pandangan mereka terhadap aturan dan kebijakan dari kampus, dengan memanfaatkan sosial media telyufess pihak kampus dapat mengetehaui bagaimanakah respond mahasiswa yang sebenernya terhdap fasilitas, kebijakan, aturan dan regulasi yang ada pada Telkom University.

Pada penelitian terdahulu telah digunakan klasifikasi tweet pada studi kasus Telyu-Fess dengan memanfaatkan metode Naïve Bayes. Pendekatan tersebut digunakan untuk memisahkan unggahan yang berkaitan dengan bidang-bidang di bawah naungan Rektorat Telkom University dari unggahan yang tidak relevan. Tujuan utama dari klasifikasi ini adalah agar informasi yang diperoleh dapat dimanfaatkan sebagai bahan evaluasi serta dasar pengembangan layanan akademik maupun administratif (Hafiz dkk., 2025). Di sisi lain, penelitian lain menerapkan analisis sentimen dengan pendekatan *lexicon-based* untuk menganalisis aduan mahasiswa, khususnya dalam mengevaluasi kinerja dosen serta efektivitas kegiatan pembelajaran (Firdaus dkk., t.t.). Selain itu, terdapat pula penelitian yang mengembangkan *chatbot* berbasis *Large Language Model* (LLM) untuk memberikan tanggapan otomatis terhadap pertanyaan mahasiswa, dengan tujuan meningkatkan efisiensi layanan informasi di lingkungan kampus. Dalam konteks pengelolaan data keluhan dan aspirasi mahasiswa, penerapan klasifikasi otomatis berbasis *Large Language Model* (LLM)

pada tingkat direktorat dapat menjadi solusi yang lebih efisien dan akurat dibandingkan dengan metode survei konvensional. Metode survei sering kali menghadapi kendala berupa rendahnya tingkat respons dari mahasiswa, baik karena kurangnya motivasi untuk memberikan jawaban aktual maupun karena persepsi bahwa survei bersifat memaksa (Hajikhani & Cole, 2024). Sejumlah penelitian sebelumnya memang telah memanfaatkan pendekatan klasifikasi berbasis *Naïve Bayes* maupun metode *lexicon-based* dalam proses pengelolaan data aduan, namun penerapannya masih terbatas pada pengelompokan aduan berdasarkan polaritas sentimen, seperti positif, negatif, atau netral. Belum terdapat penelitian yang secara khusus menerapkan LLM dalam proses klasifikasi teks untuk konteks pendidikan tinggi. Selain itu, keterbatasan juga muncul pada aspek distribusi informasi aduan, di mana keluhan yang disampaikan melalui platform Telyu-Fess belum secara efektif diteruskan kepada pihak kampus yang berwenang untuk menindaklanjutinya.

Pemanfaatan LLM sendiri sebelumnya telah diaplikasikan dalam pengembangan *chatbot* layanan informasi yang berfungsi sebagai asisten digital untuk menjawab pertanyaan pengguna secara otomatis []. Dikarenakan metode klasifikasi biasa yang lebih rumit dan menghabiskan waktu lama untuk membuat dan melatih model maka pada penelitian ini akan mengambil pendekatan yang lebih spesifik, yaitu dengan memanfaatkan LLM dalam melakukan proses klasifikasi dengan luaran artefak berupa prompt yang digunakan untuk melakukan klasifikasi dikarenakan proses klasifikasi menggunakan LLM lebih fleskibel dan tidak membutuhkan waktu lama, user hanya perlu mengunduh LLM dan melakukan konfigurasi prompt. Penelitian ini berfokus pada pengembangan *prompt* dan konfigurasi LLM menggunakan model terkuantisasi, seperti *Komodo-7B-Base-Q5_0, Meta-Llama-3.1-8B-Instruct-Q6_K*, dan *Qwen2-4B-Instruct*. Pendekatan metodologis yang digunakan adalah *Design Science Research Methodology* (DSRM), yang menekankan pada proses iteratif perancangan, pengembangan, serta evaluasi solusi berbasis artefak teknologi. Tahapan utama meliputi identifikasi masalah klasifikasi manual yang kurang efisien, dilanjutkan dengan konfigurasi dan pengembangan prompt dengan teknik few-shot prompting, untuk mengkategorikan teks mentah menjadi dua tahap pertama, deteksi teks aduan dan non-aduan, kemudian dilanjutkan dengan pelabelan otomatis ke tujuh direktorat yang ada pada kampus telkom university, terakhir dengan mengembangkan prompt yang diberikan contoh output untuk meningkatkan akurasi serta evaluasi terhadap output LLM sehingga dapat diberikan penilaian terhadap akurasi dan presisi klasifikai yang sudah dilakukan. Untuk mencapai hasil klasifikasi yang optimal, penelitian ini menitikberatkan pada penerapan *few-shot prompting* yang memberikan contoh keluaran representatif kepada LLM. Pendekatan ini bertujuan memberikan konteks semantik yang lebih baik bagi model dalam memahami pola data, sehingga dapat meningkatkan ketepatan klasifikasi teks aduan mahasiswa serta mendukung efektivitas pengambilan keputusan di lingkungan Telkom University.

Luaran utama dari penelitian ini adalah artefak yang berupa model prompt untuk mengkategorikan adua teks aduan mahasiswa berbasis LLM yang mampu mengelompokkan teks secara otomatis sesuai dengan direktorat terkait melalui penerapan *prompt engineering*. Sistem ini diharapkan dapat menjadi sarana analisis yang membantu universitas dalam menindaklanjuti keluhan mahasiswa secara cepat dan tepat. Selain itu, pendekatan yang dikembangkan memiliki potensi penerapan yang lebih luas karena sifat

LLM yang bersifat universal dan adaptif terhadap berbagai konteks data teks. Dengan demikian, metode ini dapat diimplementasikan pula pada bidang lain, seperti pengelolaan aduan publik, sistem evaluasi layanan pendidikan, maupun analisis data kelembagaan.

1.2. Rumusan Masalah

Pada sub bab ini membahas terkait masalah yang diangkat untuk penelitian.

a. Bagaimana mengembangkan model klasifikasi berbasis Large Language Model (LLM) dengan teknik prompt engineering (seperti few-shot prompting) untuk meningkatkan akurasi pengkategorian aduan?

b. Bagaimana cara yang digunakan mengevaluasi hasil output yang dihasilkan oleh LLM?

Commented [SR2]: Rumusan masalah duplicate

1.3. Tujuan Penelitian

Pada sub bab ini menjelaskan terkait fokus tujuan dari dilakukannya penelitian.

a. Merancang artefak berupa model prompt dalam bentuk website untuk mengkonfigurasi prompt, mengklasifikasi dan menampilkan hasil evaluasi.

b. Melakukan evaluasi terhdap model yang dihasilkan dengan menggunakan metode F1-score dan confusion matrix, untuk mengevaluasi output yang dihasilkan LLM.

1.4. Batasan dan Asumsi Penelitian

Pada sub bab ini menjelaskan batasan pada kegiatan penelitian

a. Penelitian ini dibatasi hanya menggunakan data tekstual berupa samples comment twitter pada periode 2023 hingga 2025.

b. Hasil klasifikasi akhir dibatasi ke dalam 7 kategori direktorat diantaranya, akademik, pasca sarjana dan advance learning, aset & sustainability, keuangan, sumber daya manusia, pusat teknologi informasi dan kemahasiswaan, pengembangan karir, alumni

c. Penelitian ini berfokus pada penggunaan LLM dan konfigurasi prompt yang digunakan dalam proses klasifikasi teks aduan.

d. Data yang digunakan berasal dari sosial media twitter telyu-fess yang berupa tweet keluhan para mahasiswa yang ditulis secara anonim.

1.5. Manfaat Penelitian

a. Penelitian ini bermanfaat bagi pihak kampus dalam menganalisis dan mengelola aduan para mahasiswa yang ada di Telkom Universiti, terutama pada sosial media, sistem yang di kembangkan dapat berguna bagi direktorat bagian, terutama pada proses penanganan keluhan mahasiswa, sehingga akan menjadi lebih efisien, respons institusi terhadap permasalahan kampus dapat dilakukan secara cepat dan terarah, serta membantu pihak universitas dalam memantau isu-isu internal berbasis data teks aduan. Dengan demikian, penelitian ini tidak hanya berkontribusi pada pengembangan teknologi LLM dalam kategori klasifikasi teks, akan tetapi juga menawarkan solusi bagi pihak kampus dalam menindak aduan para mahasiswa dengan lebih objektif dan terstruktur.

b. Manfaat bagi peneliti, penelitian ini dapat digunakan tidak hanya pada studi kasus telyu fess melainkan pada studi kasus lain yang masih memiliki keterkaitan, serta tidak ada keterbatasan bahasa yang digunkaan, dikarenakan menggunakan LLM multibahasa, sehingga penelitian ini dapat di lanjutkan untuk proses klasifikasi dengan topik yang berbeda.

1.6. Sistematika Penulisan

1. **Bagian Awal Skripsi**: Bagian awal memuat halaman sampul depan, halaman judul, halaman persetujuan dosen pembimbing, halaman pengesahan, halaman pernyataan orisinalitas, abstrak, halaman kata pengantar, halaman daftar isi, halaman daftar tabel, halaman daftar gambar, halaman daftar lampiran, dan halaman daftar istilah.

2. **Bagian Utama Skripsi** :

A. **BAB I PENDAHULUAN** : Bab ini terdiri dari latar belakang, rumusan masalah, tujuan penelitian, batasan dan asumsi penelitian, manfaat penelitian, dan sistematika penulisan skripsi.

B. **BAB II LANDASAN TEORI** : Bab ini berisi tentang penjelasan teori yang digunakan beserta alasan memilih teori dalam pembuatan tugas akhir.

C. **BAB III METODE PENELITIAN** : Dalam bab ini penulis mengemukakan tentang metode penelitian yang dilakukan oleh penulis dalam pengembangan sistem informasi.

D. **BAB IV PENGUMPULAN DAN PENGOLAHAN DATA :** Bab ini terdiri dari bagian dalam sebuah penelitian yang menjelaskan proses pengumpulan, analisis, dan pengolahan data yang diperoleh untuk mendukung tujuan dan kesimpulan penelitian.

E. **BAB V ANALISIS DAN PEMBAHASAN**: Bab ini berisi bagian dalam penelitian yang menguraikan hasil analisis data yang telah dikumpulkan dan membahas temuan-temuan tersebut dalam konteks teori, hipotesis, atau penelitian sebelumnya.

F. **BAB VI KESIMPULAN DAN SARAN** : Bab ini berisi kesimpulan dan saran dari seluruh penelitian yang telah dilakukan. Kesimpulan dapat dikemukakan masalah yang ada pada penelitian serta hasil dari penyelasaian penelitian yang bersifat analisis obyektif. Sedangkan saran berisi mencantumkan jalan keluar untuk mengatasi masalah dan kelemahan yang ada. Saran ini tidak lepas ditujukan untuk ruang lingkup penelitian.

3. **Bagian Akhir Skripsi**: Bagian akhir dari skripsi ini berisi tentang daftar pustaka dan daftar lampiran.

BAB II
LANDASAN TEORI

2.1. Literatur Terkait Teori / Konsep Umum / Model / Kerangka Kerja

Pada bab ini membahas terkait Literatur review karya ilmiah yang masih berkaitan dengan topik yang diangkat, mengambil beberapa sumber dari jurnal internasional dan menganalisis topik yang diangkat, mencari sumber referensi yang bisa digunakan agar dapat menyimpulkan hasil berdasarkan literatur review yang di baca.

No	Paper	Studi kasus	Permasalahan	Bidang Penelitian	Hasil	Konteks LLM	Metode klasifikasi
1	(B. Chen dkk., 2025)	Tidak ada	Peran prompt engineering dalam meningkatkan potensi LLM	AI	Metode dan teknik dalam prompt engineering, termasuk foundational (clear instructions, role-prompting, few-shot) dan advanced (CoT, self-consistency, generated knowledge)	Ya	Tidak
2	(Danish dkk., 2025)	Twitter	Persepsi siswa dan pendidik di India mengenai dampak dan peran ChatGPT dalam sektor pendidikan	NLP	Akurasi klasifikasi 92% dengan analisis sentimen dan tematik	Tidak	Ya, klasifikasi menggunakan model leksikon (TextBlob), BERT dan RoBERTa

No	Paper	Studi kasus	Permasalahan	Bidang Penelitian	Hasil	Konteks LLM	Metode klasifikasi
3	(Sahoo dkk., 2025)	Tidak ada	Meningkatkan kemampuan LLM tanpa modifikasi parameter, hanya melalui prompt	AI	Survei 41 teknik prompt engineering dengan peningkatan performa	Ya	Tidak
4	(Ahmed dkk., 2024)	Tidak ada	Peran DL-NLP dalam HAI untuk memahami bahasa alami dan verbal	NLP	Identifikasi BERT, Bi-LSTM, GPT	Ya	Ya, menggunakan model pre-trained untuk analisis sentimen
5	(Shao dkk., 2025)	Studi kasus hukum seperti COLIEE dan prediksi judgment	Penerapan LLM di domain hukum, pada adaptasi yurisdiksi	AI dan Hukum	Peningkatan akurasi 17.3% boost di Q&A cross-jurisdictional) dan pengurangan bias hingga 38%	Ya	Ya, klasifikasi teks hukum menggunakan Legal-BERT dan framework Toulmin
6	(Vajjala dkk., 2025)	Tidak ada	Dampak LLM pada Pendidikan, termasuk penilaian tugas	Komputasi	Tinjauan holistik tentang peluang baru dan tantangan kunci untuk aplikasi pendidikan berbasis NLP	Ya	Tidak, fokus pada tinjauan tanpa klasifikasi spesifik

No	Paper	Studi kasus	Permasalahan	Bidang Penelitian	Hasil	Konteks LLM	Metode klasifikasi
7	(Chu dkk., t.t.)	Tidak ada	Tantangan seperti generasi umpan balik, desain kurikulum, isu etis, dan bias	Pendidikan dan AI	Peningkatan signifikan dalam tugas pendidikan melalui agen LLM, dengan analisis dataset dan benchmark	Ya	Ya, menggunakan framework algoritma untuk klasifikasi tugas, pada domain pendidikan
8	(Abd-Alrazaq dkk., 2023)	Studi kasus, analisis feedback, survei dan penilaian terhdapa tugas matematika	Kurangnya pengetahuan dan pengalaman belajar LLM beserta dampaknya	Data Analisis	LLM mencapai performa setara manusia di penilaian tugas, dengan peningkatan hingga 20-30% dari manusia asli	Ya	Ya, chain-of-thought prompting dan fine-tuning seperti DeBERTa untuk klasifikasi jawaban
9	(Feng dkk., t.t.)	Eksperimen kolaborasi manusia dan simulasi agen AI	Kekurangan LLM dalam menyesuaikan buadaya dan kebutuhan manusia	AI	Peningkatan performa signifikan dalam tugas dengan menggunakan metode ReHAC berbasis RL	Ya	Tidak, fokus pada kebijakan RL tanpa klasifikasi

No	Paper	Studi kasus	Permasalahan	Bidang Penelitian	Hasil	Konteks LLM	Metode klasifikasi
11	(Beale, 2025)	Tidak ada	Tantangan desain untuk LLM sebagai sistem pendidikan yang efektif	HCI	LLM merevolusi ekspektasi pengguna, dengan keberhasilan di berbagai domain pendidikan	Ya	Tidak
12	(Sharma dkk., 2025)	Tidak ada	Kesenjangan dalam penyelarasan keadilan budaya dengan optimasi waktu proses yang rendah	AI	Analisis komparatif algoritma dasar seperti PPO dan DPO, dengan outline tantangan terbuka	Ya	Ya, analisis algoritma penyelarasan seperti GRPO
13	(Plaat dkk., 2025)	Tidak ada	Kemampuan penalaran LLM yang terbatas	AI	Kemajuan signifikan di luar masalah matematika, dengan penggunaan RL untuk fine-tuning	Ya	Ya, clustering untuk generasi, dan evaluasi
15	(Ge dkk., 2025)	Tidak ada	Teknik coding dengan LLM untuk aplikasi kreatif	Komputasi dan Bahasa	Identifikasi tren dan aplikasi dalam coding berbasis LLM	Ya	Tidak
17	(Mei dkk., 2025)	Tidak ada	Bias dan window limits	Komputasi dan Bahasa	Peningkatan QA akurasi (e.g., HippoRAG); 30% accuracy drop mitigated	ya	Ya, RAG variants, CoT

No	Paper	Studi kasus	Permasalahan	Bidang Penelitian	Hasil	Konteks LLM	Metode klasifikasi
18	(Minaee dkk., 2025)	Tidak ada	Scalabilit dan alignment	NLP dan AI	SOTA on benchmarks (e.g., Med-PaLM 86.5% on MedQA)	ya	Ya, Causal LM, masked LM, RLHF, DPO
19	(Ronanki dkk., 2025)	Tidak ada	Keterbatasan domain sepsifik untuk RE	Software Engineering	36 panduan berhasil dibuat dengan 9 optimisasi model	ya	Tidak
20	(Vatsal dkk., 2025)	Tidak ada	Keterbatasan pemahaman bahasa dan verbal	NLP	SoTA seperti ChatIE untuk NER	ya	Tidak
21	(Shahzad dkk., 2025)	Konten Tutorial	Data privacy, bias, Ketergantungan terhadap AI	AI dan pendidikan	Framework with pillars for personalization; efficiency gains	ya	Tidak
22	(Zdravkova & Ilijoski, 2025)	Program belajar etika menggunakan komputer	Superficial research dan plagiarism	Pendidikan	Menurunkan tingkat plagiarisme	ya	Tidak

No	Paper	Studi kasus	Permasalahan	Bidang Penelitian	Hasil	Konteks LLM	Metode klasifikasi
23	(Anam, 2025)	Keefektifan prompt engineering dalam meningkatkan produktivitas	Pandangan pelajar terhadap prompt engineering	Pendidikan	Pendapat responden terhdap Prrompt engineering	ya	Tidak
Pembahasan Literature Review :			Penelitian ini menggunakan metode prompt engineering dan LLM sebagai prioritas utama dalam menentukan urgensi, **metode klasifikasi** digunakan sebagai referensi metode yang bisa pakai pada penelitian ini.				

Table 2.1.1 Literature Review

Tabel 2.1.1 digunakan untuk membandingkan relevansi penelitian ini dengan penelitian terdahulu, sebagaimana pada tabel tersebut didapatkan bahwa penggunaan LLM dalam pengklasifikasian teks masihlah sangat terbatas, dan dengan adanya penelitian ini pengimplementasian LLM untuk melakukan klasifikasi teks menggunakan LLM dapat di implementasikan dan digunakan untuk melakukan pengklasifikasian tidak hanya sebatas pada aduan kampus saja, akan tetapi dapat digunakan secara general bahkan diluar konteks perguruan tinggi.

2.1.1. Library Python

Lybrary python adalah pakage yang berisi kumpulan fungsi python yang bisa langsung dipakai, dengan mengunduh dan memanggil pakage tersebut. Pada Subab 2.1.9 akan di jelaskan terkait library apa saja yang digunakan dalam penelitian ini, dengan penjelsan di setiap library yang di gunakan beserta fungsi dari library tersebut.

No	Library	Penjelasan	Fungsi dalam Penelitian
1	LangChain	Framework open-source untuk membangun aplikasi berbasis LLM dengan pendekatan modular dan berorientasi yang saling terhubung seperti rantai. (Mavroudis, t.t.).	Menghubungkan model LLM dengan teks yang diproses, mengelola prompt templates, dan mengoordinasikan alur kerja klasifikasi.
2	llama-cpp-python	Llaama.cpp yang berupa library python, memungkinkan inferensi LLM secara efisien pada perangkat device yang digunakan (*llama.cpp*, t.t.).	Engine utama untuk menjalankan model LLM (Komodo, Llama, Qwen) secara lokal dengan optimasi kuantisasi.
3	PyTorch	Framework deep learning yang menyediakan computation dan neural networks dengan akselerasi GPU (Paszke dkk., 2019).	Menyediakan infrastruktur komputasi untuk operasi neural network dan integrasi dengan model transformer.
4	Transformers	Library yang menyediakan arsitektur transformer dan model pre-trained untuk NLP (Wolf dkk., t.t.).	Menyediakan arsitektur dasar dan komponen model LLM yang digunakan dalam pipeline.
5	scikit-learn	Library machine learning yang menyediakan alat untuk data mining dan analisis data (PedregosaFABIANPEDREGOSA dkk., 2011) (Buitinck dkk., 2013).	Digunakan untuk evaluasi model dengan metrik klasifikasi (accuracy, precision, recall, F1-score).
6	pandas	Library untuk manipulasi dan analisis data terstruktur (Mckinney, t.t.).	Digunakan untuk memuat, membersihkan, dan memanipulasi dataset tweet dari file CSV.
7	NumPy	Library fundamental untuk komputasi numerik dengan array multidimensi (Harris dkk., 2020).	Mendukung operasi matematika dan manipulasi array untuk pra-pemrosesan data.
8	SQLAlchemy	Toolkit SQL dan Object-Relational Mapping (ORM) untuk Python (Brown & Wilson, t.t.) (Bayer & Contributors, 2024).	Mengelola koneksi dan interaksi dengan database untuk menyimpan hasil klasifikasi.
9	openpyxl	Library untuk membaca/menulis file Excel format xlsx (*openpyxl*, t.t.) (Clark & Contributors, 2024).	Digunakan untuk ekspor hasil klasifikasi ke format spreadsheet yang mudah dibaca.
10	Flask	Micro web framework untuk Python yang ringan (Bednarz & Miłosz, 2025).	Menyediakan API endpoint untuk integrasi proses klasifikasi dengan aplikasi web.

Table 2.1.2 Library Python

Commented [SR3]: Beberapa referensi diupdate

Commented [SR4]: Beberapa referensi diupdate

Commented [SR5]: Beberapa referensi diupdate

Commented [SR6]: Beberapa referensi diupdate

Pada tabel 2.1.3 dijelaskan berbagai jenis library yang digunakan pada sistem, dengan fungsi yang berbeda, setiap library tersebut nantinya akan slaing dihubungkan menggunakan langchain agar seriap proses dapat dengan mudah di jalankan tanpa perlu menjalankan setiap fungsi satu persatu.

2.1.2. NLP natural language processing

Natural Language Processing (NLP) adalah bidang di AI yang menguji bagaimana sistem komputer dapat menjelaskan dan mengontrol bahasa alami, baik dalam bentuk teks maupun ucapan. NLP merupakan bagian penting dari instruksi yang memungkinkan agen seperti chatbot atau IOT untuk berinteraksi dengan manusia (Danish dkk., 2025). NLP pada penelitian ini sendiri adalah sebagai konsep dimana untuk mencapai tujuan awal pada penelitian ini yaitu untuk menciptakan sebuah sistem yang dapat memahami dan mengklasifikasikan bahasa alami dalam hal ini, aduan mahasiswa di media sosial telyufess secara otomatis dan akurat.

2.1.3. Transformer

Transformer adalah sebuah arsitektur jaringan saraf (neural network) yang diperkenalkan dalam paper (Vaswani dkk., t.t.) (Tay dkk., 2022). Secara sederhana, Transformer adalah *framework* untuk memproses data sekuensial, seperti kalimat bahasa alami. Transformer bertujuan untuk merevolusi bidang NLP dalam mengatasi keterbatasan model sebelumnya, metode *Recurrent Neural Networks* (RNN) dan *Long Short-Term Memory* (LSTM) dengan menggunakan *self attention*, yang digunakan sebagai inti untuk memberikan pemahaman kepada sistem bahwasannya kata yang diolah dapat menjadi suatu makna, dan dapat menguhubungkan antar kalimat dengan baik sehingga terlihat natural.

Commented [SR7]: Beberapa referensi diupdate

2.1.4. LLM (large language model)

Secara umum *Large Language Model* (LLM) adalah model kecerdasan buatan yang dilatih dengan jumlah data teks yang sangat besar (miliaran hingga triliunan kata) untuk memahami, memproses, dan menghasilkan bahasa manusia (Zhang dkk., 2024). Dalam tahap pengembangan, LLM biasanya mengalami beberapa fase penyempurnaan setelah pelatihan awal. Selanjutnya, penyesuaian dengan bahasa yang digunakan untuk memastikan keluaran yang sesuai. Dalam konteks ini LLM sebagai objek penelitian berperan sebgai inti objek penelitian untuk melakukan klasifikasi.

2.1.5. Prompt Engineering

prompt engineering merupakan suatu teknik dalam yang digunakan dalam merancang dan mengoptimalkan instruksi (prompt) yang diberikan kepada model AI, khususnya LLM, untuk menghasilkan output yang diinginkan dengan akurat dan konsisten (Marvin dkk., 2024). Konteks prompt engineering digunakan dalam mengarahkan LLM dalam memberikan output yang paling sesuai dan relevan sesuai dengan tujuan awal dari klasifikasi.

2.1.6. Design Science Research Methodology

Design Science Research Methodology (DSRM) adalah sebuah metodologi penelitian yang berfokus pada perancangan dan penciptaan "artefak" baru untuk

memecahkan masalah yang diidentifikasi dalam dunia nyata. Berbeda dengan metodologi yang hanya menganalisis atau menjelaskan fenomena (seperti studi kasus kualitatif), DSRM bertujuan untuk menciptakan sesuatu yang baru dan kemudian mengevaluasi kegunaannya (Peffers dkk., t.t.) (Drechsler & Hevner, 2022). Penelitian ini menggunakan DSRM sebagai metode yang digunakan dalam melakukan penelitian, dengan hasil (artefak), sistem yang dihasilkan dan prompt yang konfigurasi.

2.1.7. Crawling

Crawling adalah proses otomatis yang menggunakan sebuah program untuk melakukan proses pengambilan pencarian dan pengambilan data dari internet, biasanya disebut crawler atau spider. Pada penelitian ini crawler yang digunakan adalah tweet harvest yang akan mengambil semua tweet dari akun telyufess, dengan rentan tanggal yang sudah di tentukan.

2.1.8. Teks Processing

Teks Processing adalah teknik yang digunakan untuk mengubah teks mentah (raw text) menjadi bentuk yang terstruktur sehingga siap diproses sehingga dapat digunakan dalam proses klasifikasi oleh LLM (Hino & Fahey, 2019) (Poth, 2023). Teksprocessing digunakan untuk mengolah data dari sosial media telyufess yang berupa CSV dan masih memiliki berbagai attribut yang tidak digunakan untuk pengklasifikasian.

Commented [SR8]: Beberapa referensi diupdate

2.1.9. Evaluasi

Evaluasi digunakan untuk mengukur seberapa akurat output yang dihasilkan oleh LLM dengan melakukan perbandingan terhadap data acuan, penggunaan beberapa rumus evaluasi digunakan untuk memastikan apakah LLM memeberikan data yang akurat dan rerlevan (Sokolova & Lapalme, 2009).

1. **Akurasi (Accuracy)** merupakan metrik paling dasar untuk mengevaluasi performa model klasifikasi secara keseluruhan. Akurasi dihitung sebagai rasio jumlah prediksi yang benar (baik benar positif maupun benar negatif) terhadap total seluruh data uji. Secara matematis, akurasi didefinisikan sebagai $\frac{\sum_{i=1}^{N} TP_i}{\sum_{i=1}^{N}(TP_i+FP_i+FN_i+TN_i)}$ di mana TP_i, FP_i, FN_i, dan TN_imasing-masing adalah true positive, false positive, false negative, dan true negative pada kelas ke-i, sedangkan Nadalah jumlah kelas. Metrik ini memberikan gambaran umum seberapa sering model membuat prediksi yang tepat, namun dapat menyesatkan jika data sangat tidak seimbang (imbalanced).

2. **Presisi (Precision)** mengukur tingkat ketepatan model ketika menyatakan suatu instance termasuk dalam kelas positif. Dengan kata lain, dari semua data yang diprediksi sebagai kelas positif, berapa proporsi yang benar-benar positif. Rumus presisi untuk suatu kelas adalah $\text{Precision}_i = \frac{TP_i}{TP_i+FP_i}$ Nilai presisi yang tinggi menunjukkan bahwa model jarang salah mengklasifikasikan instance negatif sebagai positif (rendah false positive). Dalam konteks pengelompokan aduan, presisi yang tinggi sangat penting agar aduan tidak dialihkan ke direktorat yang salah.

3. **Recall (Recall/Sensitivity)** mengukur kemampuan model dalam menemukan semua instance yang sebenarnya termasuk kelas positif. Recall menjawab pertanyaan: dari semua data yang benar-benar positif, berapa proporsi yang berhasil dideteksi oleh model? Rumusnya adalah $\text{Recall}_i = \frac{TP_i}{TP_i + FN_i}$ Recall yang tinggi berarti model mampu menangkap sebagian besar kasus positif (rendah false negative). Pada sistem pengelompokan aduan, recall yang baik memastikan aduan penting tidak terlewat dan tetap diteruskan ke direktorat yang sesuai.

4. **F1-Score** adalah rata-rata harmonik dari presisi dan recall, sehingga memberikan keseimbangan antara keduanya. F1-Score sangat berguna ketika kita ingin menghindari situasi di mana salah satu metrik (presisi atau recall) tinggi tetapi yang lain sangat rendah. Rumus F1-Score per kelas adalah $\text{F1-Score}_i = 2 \times \frac{\text{Precision}_i \times \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i}$ Karena menggunakan rata-rata harmonik, F1-Score lebih sensitif terhadap nilai yang rendah dibandingkan rata-rata aritmatika biasa. Metrik ini jauh lebih representatif daripada akurasi ketika distribusi kelas tidak seimbang.

Dengan menggunakan rumus-rumus tersebut output dari LLM dapat diukur dan didapatkan hasil yang bisa digunakan dalam melakukan perbandingan dengan menggunakan metode klasifikasi lainnya.

2.2. Alasan Pemilihan Teori / Model / Kerangka Kerja

Bagian ini akan menjelaskan alasan pemilihan teori yang digunakan dalam penelinitian ini, termasuk perbandingan dengan pendekatan algoritma machine learning tradisional dan LLM.

Pertama, mari kita bahas alasan pemilihan LLM untuk klasifikasi teks. LLM, seperti GPT atau Llama, telah menunjukkan kemampuan superior dalam memproses bahasa alami dibandingkan dengan model tradisional yang masih menggunakan algoritma seperti SVM. Menurut penelitian dari, LLM seperti Llama3 dan GPT-4 mampu mengungguli metode tradisional dalam tugas klasifikasi multiclass yang kompleks, seperti pengklasifikasian ulasan pekerjaan atau berita palsu, meskipun dengan biaya inferensi yang lebih tinggi (Kostina dkk., 2025). Hal ini karena LLM memiliki pemahaman bahasa alami yang lebih baik sehingga memungkinkan LLM dalam memproses dan memahami maksud dari teks bahasa gaul (slang), sarkasme, atau konteks implisit dalam teks aduan mahasiswa berbeda dengan model tradisional seperti Support Vector Machine (SVM) atau Naive Bayes. Dalam konteks penelitian ini, data dari Telyufess yang digunakan tidak terlabel secara massal, sehingga LLM dengan penerapan few-shot prompting menjadi ideal. Few-shot prompting memungkinkan konfigurasi prompt yang spesifik untuk tujuh label direktorat (misalnya, Direktorat Akademik, Keuangan, dll.), tanpa memerlukan fine tuning yang sifatnya lama dan kurang efisien.

Untuk memperkuat alasan ini, berikut adalah perbandingan antara LLM dengan algoritma sejenis (traditional ML dan deep learning NLP seperti BERT). Perbandingan ini disusun berdasarkan metrik kunci seperti kebutuhan data, akurasi, fleksibilitas, dan biaya komputasi, yang diadaptasi dari berbagai sumber terkini seperti studi dari (Ghaffarzadeh-Esfahani dkk., 2025; The state of AI in 2025 Agents, innovation, and transformation, 2025).

Aspek	LLM	Algoritma Tradisional	Deep Learning NLP
Kebutuhan Data	Rendah (zero/few-shot)	Tinggi (ribuan label)	Tinggi (fine-tuning butuh data)
Waktu Training	Lama	Cepat	Lama (fine-tuning)
Fleksibilitas	Tinggi (adaptif ke task baru)	Rendah tugas spesifik	Sedang (pre-trained, tapi butuh tuning)
Biaya Komputasi	Berat pada pemakaian hardware	Rendah	Berat pada pemakaian hardware
Kelebihan	Memahami banyak bahasa dan konteks	Pemahaman algoritma dalam memahami permasalahan dan memecahkan masalah lebih baik.	Bagus untuk teks panjang
Kekurangan	Rentan bias	Kurang memahami teks yang typo atau salah huruf	Butuh data label banyak

Commented [SR9]: Alasan pemilihan model dibuat tabel perbandingan LLM dengan algoritma sejenis

Table 2.2.1 Perbandingan LLM dengan Algoritma lain

Dari tabel di atas, terlihat bahwa LLM unggul dalam fleksibilitas dan pemahaman konteks, yang krusial untuk data aduan dari sosial media. Studi dari (Ghaffarzadeh-Esfahani dkk., 2025), menunjukkan bahwa meskipun LLM zero-shot hanya mencapai F1 score 0.43 dalam prediksi mortalitas COVID 19, fine-tuning dengan QLoRA meningkatkannya hingga 0.74, mendekati performa traditional ML seperti XGBoost (0.87). Namun, untuk penelitian ini, saya memilih pendekatan prompt engineering daripada fine-tuning, dikarenakan lebih efisien, alasannya fine-tuning berisiko overfit atau memerlukan hardware dengan spesifikasi yang cukup tinggi, Prompt engineering memungkinkan konfigurasi cepat.

Alasan lain pemilihan LLM adalah adaptasi terhadap kasus lain di luar Telyufess, seperti aduan di platform lain atau domain pendidikan umum. Machine learning Tradisional, meskipun efisien, memerlukan redesign model untuk setiap task baru, sementara LLM bisa diadaptasi hanya dengan modifikasi prompt. Misalnya, dalam sentiment analysis, LLM seperti GPT4 mampu menangani nuansa emosional yang tidak tertangkap oleh TF-IDF dengan Logistic Regression, seperti yang dibahas dalam (Kallstenius dkk., 2025). Dalam penelitian ini, kami menggunakan LLM untuk mengklasifikasikan teks ke tujuh kategori, dengan evaluasi menggunakan F1 score dan confusion matrix, untuk memastikan akurasi yang tinggi sambil menjaga adaptivitas.

Selain model, pemilihan DSRM sebagai kerangka kerja metodologi juga didasarkan pada sifat penelitian yang berorientasi pada pembuatan artefak. DSRM, yang dikembangkan oleh (Kallstenius dkk., 2025) dan diperbarui dalam literatur terkini, cocok untuk penelitian desain sains yang menghasilkan solusi praktis seperti model prompt dan web UI. Alasan utamanya adalah definisi tujuan, desain artefak, demonstrasi, evaluasi, dan komunikasi. Ini sesuai dengan kebutuhan penelitian ini, di mana artefak berupa sistem

klasifikasi LLM perlu dievaluasi secara rinci menggunakan data ground truth yang divalidasi oleh direktorat terkait.

Pemilihan teori-teori pendukung seperti Natural Language Processing (NLP) dan Transformer sebagai dasar LLM juga relevan. Transformer memungkinkanuntuk emnggunakan metode efisien untuk teks panjang, sementara NLP menyediakan fondasi untuk teks processing seperti tokenisasi. Alasan tidak memilih NLP murni adalah keterbatasannya dalam menangani variasi bahasa Indonesia informal di Telyufess, seperti singkatan atau slang, yang lebih baik ditangani oleh LLM.

Secara keseluruhan, pemilihan ini didasarkan pada pertimbangan berdasarkan performa, efisiensi, dan relevansi dengan masalah. Meskipun ML masih unggul dalam data tabular berstruktur seperti dalam studi (Kallstenius dkk., 2025), di mana NLP tradisional mencapai 95% akurasi vs LLM 91%, untuk teks aduan tidak terstruktur, LLM dengan prompt engineering memberikan nilai tambah yang signifikan. Penelitian ini diharapkan berkontribusi pada peningkatan layanan kampus melalui analisis data sosial media yang lebih akurat.

Commented [SR10]: Teori di bab 2 perlu diperluas, tidak hanya 1 paragraf

BAB III
METODOLOGI PENELITIAN

3.1 Sistematika Penyelesaian Masalah

Bab ini membahas metodologi dan prosedur pelaksanaan klasifikasi dengan pendekatan Design Science Research Methodology (DSRM) yang telah ditetapkan, dan diilustrasikan melalui diagram alur penelitian yang menggambarkan enam tahapan proses iteratif berbasis penciptaan artefak yang berupa sistem dan evaluasi terhdap klasifikasi.

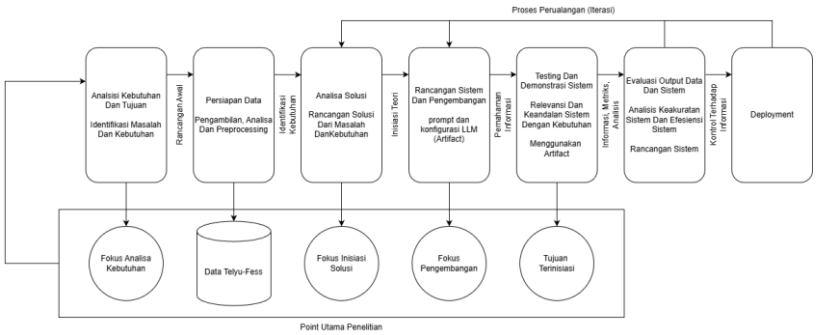

Gambar 3.1 Diagram Metodologi Penelitian

Dalam penelitian ini, luaran yang dihasilkan tidak terbatas pada data hasil proses klasifikasi, melainkan juga mencakup artefak berupa model prompt yang dirancang untuk menyelesaikan permasalahan klasifikasi sentimen pada data Telyu-Fess. Pengembangan artefak ini mengikuti proses DSRM pada gambar 3.1 terdiri dari tujuh tahapan metodologis sebagai berikut:

1. kebutuhan berdasarkan permasalahan yang diidentifikasi.
2. Persiapan data yang akan digunakan.
3. Menetapkan tujuan solusi, yakni merancang prompt dan konfigurasi LLM yang mampu menghasilkan klasifikasi sentimen dengan akurasi tinggi.
4. Design & Development Proses perancangan dan pengembangan artefak berupa:
    a. Prompt engineering.
    b. Konfigurasi hyperparameter LLM.
    c. Template prompt standar untuk konsistensi output.
5. Demonstration Uji coba artefak (prompt dan konfigurasi LLM).
6. Evaluation rumus evaluasi yang digunakan terhadap performa.
7. Communication (menuju Deployment) Dokumentasi artefak dalam bentukpanduan penggunaan, template prompt, dan konfigurasi optimal, serta implementasi dalam lingkungan nyata.

Metode DSRM memungkinkan iterasi antara tahapan apabila hasil evaluasi menunjukkan kekurangan, sehingga dapat terus disempurnakan hingga memenuhi kriteria utilitas, efikasi, dan generalisabilitas dalam konteks klasifikasi sentimen berbasis bahasa Indonesia informal.

3.2 Metodologi DSRM

Pemilihan metode Design Science Research Methodology (DSRM) diterapkan dalam penelitian ini dengan pertimbangan bahwa kerangka kerja tersebut dinilai sesuai untuk pengembangan artefak berupa model prompt untuk menyelesaikan permasalahan klasifikasi sentimen pada studi kasus Telyu-Fess. Metodologi ini bersifat iteratif dan berorientasi pada penciptaan solusi praktis. Melalui penerapan ketujuh tahapan pada metode DSRM, diharapkan artefak yang dihasilkan, yaitu model prompt akan memiliki tingkat akurasi, interpretabilitas, efisiensi, dan adaptabilitas yang tinggi serta sesuai dengan kebutuhan dan analisis sentimen berbasis bahasa Indonesia pada data media sosial X Telyufess.

3.2.1 Analisis Kebutuhan

Berdasarkan identifikasi kebutuhan, proses klasifikasi manual yang selama ini dilakukan memerlukan waktu yang signifikan sehingga berpotensi menurunkan tingkat efisiensi. Untuk mengatasi permasalahan tersebut, dikembangkan model prompt menggunakan LLM untuk mengkateogrikan teks aduan dan direktorat yang mampu secara otomatis memfilter dan mengkategorikan keluhan mahasiswa pada platform Telyu-Fess guna mengidentifikasi permasalahan terkait lingkungan kampus.

Tahap awal dalam proses klasifikasi ini adalah pra-pemrosesan data dari sumber Telyu-Fess dengan memanfaatkan kata kunci untuk menyaring teks yang bersifat aduan dan non-aduan. Setelah memperoleh teks aduan mahasiswa, tahap selanjutnya adalah mengklasifikasikan teks aduan tersebut ke dalam tujuh direktorat yang terdapat di lingkungan kampus sesuai dengan karakteristik aduan. Berikut merupakan ketujuh direktorat tersebut:

1. Direktorat Akademik, Direktorat ini menangani segala hal terkait perkuliahan, proses pembelajaran, dan administrasi akademik.
2. Direktorat Pascasarjana dan Advance Learning, Direktorat ini bertanggung jawab terhadap program pascasarjana, studi lanjut, dan proses wisuda.
3. Direktorat Aset & Sustainability, Direktorat ini mengurusi seluruh fasilitas dan aset kampus yang tersedia.
4. Direktorat Keuangan, Direktorat ini menangani segala bentuk pembayaran dan keuangan, termasuk BPP, UKT, serta komponen pembayaran lainnya.
5. Direktorat Sumber Daya Manusia, Direktorat ini berkaitan dengan pengelolaan staf, dosen, dan mahasiswa.
6. Direktorat Pusat Teknologi Informasi, Direktorat ini bertanggung jawab terhadap perangkat lunak, keamanan, dan infrastruktur digital.
7. Direktorat Kemahasiswaan, Pengembangan Karir, dan Alumni, Direktorat ini menangani kegiatan magang, kerja praktik, serta pengembangan karir.

Seluruh direktorat tersebut akan dijadikan sebagai acuan dalam mengklasifikasikan teks aduan sesuai dengan ketentuan yang berlaku.

3.2.2 Data Preparation

Tahap persiapan data diawali dengan teknik pengumpulan data melalui metode crawling. Tools Tweet Harvest digunakan untuk proses akuisisi data. Data diambil dari periode tahun 2023 hingga 2025, dengan total jumlah data sebanyak 15966 data.

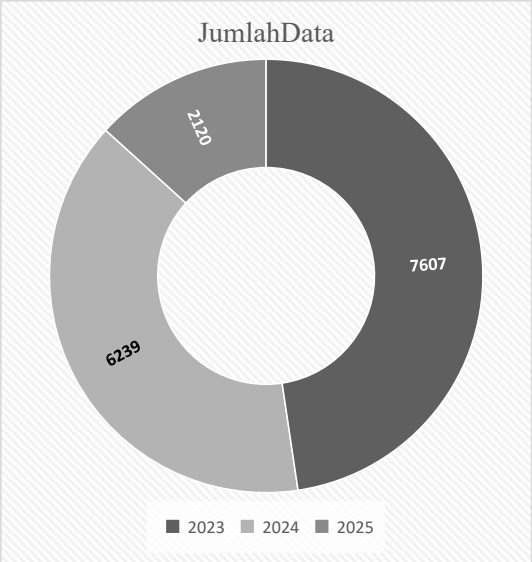

Gambar 3.2.1 Jumlah Data

Pada Gambar 3.2.1 ditinjukan jumlah data dari setiap tahunnya, setelah data target berhasil diperoleh, tahap selanjutnya adalah proses pra-pemrosesan teks untuk mengubah data mentah menjadi data yang siap untuk proses klasifikasi.

1. Unprocessed text

Data masih tersimpan dalam format CSV dan memuat berbagai kolom, antara lain: conversation_id_str, created_at, favorite_count, full_text, id_str, image_url, in_reply_to_screen_name, lang, location, quote_count, reply_count, retweet_count, tweet_url, user_id_str, dan username. Berdasarkan analisis kebutuhan penelitian, kolom yang diperlukan hanyalah kolom full_text. Hal ini dikarenakan fokus utama penelitian adalah menguji performa klasifikasi Large Language Model (LLM) melalui teknik prompting. Dengan demikian, luaran yang dihasilkan nantinya berupa hasil berbagai prompt yang diujikan dan model LLM yang digunakan, guna menentukan konfigurasi optimal untuk proses klasifikasi.

2. Processed text

Teks terproses merupakan hasil mengubah data yang pada data awal masih mengandung kalimat dengan banyak komponen seperti tanggal, jumlah tweet, link tweet tersebut dan jumlah likes. Teks yang telah melalui tahap pra-pemrosesan dan siap untuk dilakukan klasifikasi aduan akan berupa teks dari tweet yang dibuat melalui bot telyufess. Ada beberapa tahapan dalam pemrosesan teks dan berikut adalah bebeerapa tahapan yang dilakukan untuk melakukan preprocessing teks.

a. Pembersihan Teks (Symbol, mention, hashtag, emoticon)

Dilakukan penghapusan symbol kecuali (?,.,!,/). Selain itu, dilakukan eliminasi terhadap mention (@username) dan hashtag (#tag) yang tidak memiliki kontribusi semantik signifikan dalam konteks klasifikasi konten teks.

b. Penanganan Kesalahan Ketik dan Singkatan

Dilakukan koreksi terhadap kesalahan pengetikan yang umum terjadi pada istilah akademik, seperti "tel-u" menjadi "telyu".

Setelah melalui tahap pra-pemrosesan teks, data yang telah ditransformasi akan berupa teks saja dengan kata kata yang sudah di perjelas untuk mempermudah LLM dalam prses kleasifikasi.

3.2.3 Rancangan Solusi Dari Masalah Dan Kebutuhan

Bagian ini membahas rancangan solusi yang dirancang secara sistematis untuk mengatasi permasalahan klasifikasi aduan pada studi kasus Telyu-Fess, dengan mengacu pada analisis kebutuhan yang telah dirumuskan pada tahapan Identify Problem & Motivate dalam metode DSRM.

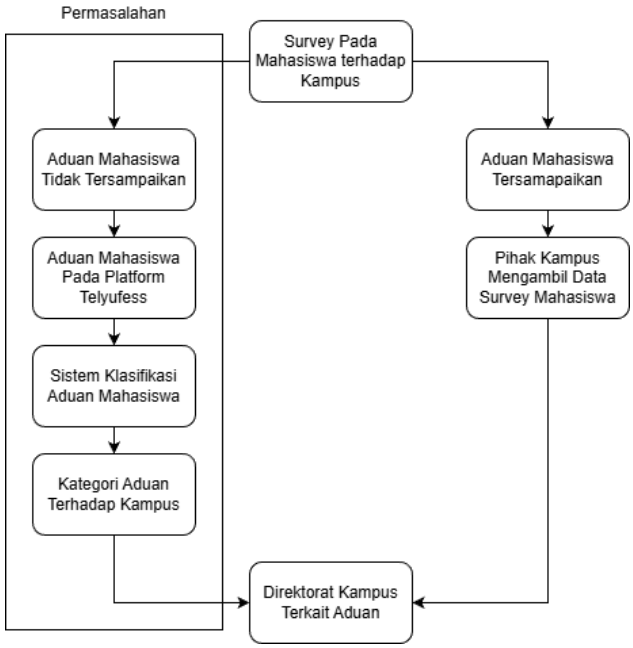

Gambar 3.2.2 Alur Penyelesaian Permasalahan

Seperti pada Gambar 3.2.1, dibutuhkannya artefak berupa model prompt menggunakan LLM untuk melakukan klasifikasi aduan mahasiswa pada platform Telyufess agar pihak kampus mengetahui dan mengidentifikasikan aduan para mahasiswa yang belum tersampaikan.

3.2.3.1 Analisis Kebutuhan

Berdasarkan identifikasi permasalahan sebelumnya, disimpulkan bahwa diperlukan artefak berupa prompt dan konfigurasi LLM yang mampu melakukan

klasifikasi teks secara bertahap pada data dari akun media sosial Twitter @telyufess. Proses klasifikasi mencakup dua tahap utama:

1. Klasifikasi Aduan: Mengidentifikasi apakah suatu tweet termasuk aduan atau non-aduan misalnya: opini, informasi, atau obrolan biasa.
2. Klasifikasi Direktorat: Bagi tweet yang terdeteksi sebagai aduan, lakukan pengelompokan ke dalam direktorat terkait (misalnya: Direktorat Akademik, Direktorat Kemahasiswaan, Direktorat Sarana & Prasarana, Direktorat Keuangan, atau Direktorat Umum).

Kebutuhan utama meliputi:

a. Akurasi tinggi dalam konteks bahasa informal, sarkasme, slang kampus, dan singkatan khas mahasiswa Telkom University.
b. Interpretabilitas hasil klasifikasi (dapat menjelaskan alasan pengelompokan).
c. Efisiensi komputasi agar dapat dijalankan secara real-time atau batch pada infrastruktur terbatas.
d. Skalabilitas untuk menangani volume tweet harian yang fluktuatif.
e. Adaptabilitas terhadap perubahan pola bahasa dan munculnya topik aduan baru.
f. Tidak memiliki limitasi dalam menghasilkan output

Kebutuhan non-fungsional mencakup integrasi langsung pada sistem telyufess dan penggunaan pada proses nyata.

3.2.3.2 Analisa Solusi

Penggunaan LLM berbasis Instruct Model dipilih sebagai solusi karena kemampuannya dalam memahami konteks bahasa alami, menangani variasi linguistik, dan melakukan klasifikasi berbasis prompt tanpa memerlukan pelatihan ulang model (fine tuning).

Alasan pemilihan LLM sebagai solusi utama:

1. Kemampuan generalisasi tinggi: LLM telah dilatih menggunakan data yang sangat besar, termasuk data media sosial, sehingga mampu mengenali pola bahasa informal.
2. Fleksibilitas melalui prompt engineering: Klasifikasi dapat diarahkan sepenuhnya melalui instruksi teks tanpa modifikasi pada model, sehingga lebih cepat, hemat biaya, dan mudah diperbarui.
3. Dukungan chain-of-thought (CoT): Memungkinkan LLM untuk berpikir langkah demi langkah sebelum memberikan keputusan, meningkatkan akurasi dan interpretabilitas.
4. Efisiensi dalam klasifikasi : Dengan konfigurasi parameter yang, output menjadi relevan.

Alternatif solusi lain yang tidak digunakan:

a. Fine-tuning BERT kecil: Memerlukan data berlabel besar, infrastruktur GPU, dan proses pelatihan ulang saat pola aduan berubah.
b. Rule-based system: Sulit diskalakan untuk ribuan variasi ekspresi aduan.

3.2.4 Design & Development Proses

Bagian ini menguraikan proses few-shot prompting serta format yang diterapkan dalam perancangan prompt. Dilakukan pengkategorian terhadap komponen-komponen prompt yang digunakan, dengan poin poin berikut:

1. Arsitektur LLM
2. Setup Library
3. Konfigurasi Prompt
4. Konfigurasi Parameter

Format prompt yang dikembangkan bersifat fleksibel dan dapat disempurnakan pada tahap penelitian selanjutnya, baik melalui reduksi beberapa komponen maupun penambahan elemen baru. Dengan mengadopsi format prompt tersebut, diharapkan Large Language Model (LLM) mampu melakukan proses pengklasifikasian dengan tingkat akurasi yang optimal.

3.2.4.1 Arsitektur Sistem

Tahap selanjutnya dalam penelitian ini adalah proses seleksi model Large Language Model (LLM) dan framework yang akan digunakan dalam proses klasifikasi. Berdasarkan analisis kebutuhan, model yang dipilih harus memenuhi beberapa kriteria tertentu. Pertama, model harus bersifat open-source yang memungkinkan akses dan penggunaan secara gratis tanpa batasan lisensi. Kedua, model harus secara khusus didesain untuk pemrosesan teks mengingat fokus utama penelitian ini adalah klasifikasi teks.

3.2.4.2 Setup library utama yang digunakan

Untuk mendukung implementasi few-shot prompting, diperlukan beberapa konfigurasi awal yang meliputi library Python dan setup prompt. Berikut merupakan konfigurasi library utama yang digunakan dalam penelitian ini.

1. LangChain

Library LangChain berfungsi sebagai penghubung antara model dan teks yang diproses, sedangkan llama-cpp memungkinkan model dijalankan secara lokal.

2. Llama-CPP

Secara fungsi, llama-cpp berperan sebagai engine utama untuk eksekusi model secara lokal. Keunggulan llama-cpp terletak pada efisiensinya yang tinggi, mengingat basis kode dikembangkan menggunakan bahasa pemrograman C/C++. Selain itu, llama-cpp digunakan untuk melakukan proses tokenisasi pada model, sehingga ukuran model dapat dikompresi dan lebih ringan saat dijalankan pada mesin lokal.

3. **Torch**

Library Torch merupakan komponen kritikal dalam penelitian ini, mengingat fungsinya sebagai framework fundamental untuk menjalankan model secara optimal. Torch menyediakan infrastruktur komputasi yang diperlukan untuk operasi neural network.

4. **Flask**

Flask digunakan untuk menampilkan interface agar user dapat melihat dan melakukan klasifikasi pada platform website.

3.2.4.3 Konfigurasi Prompt

Untuk mengoptimalkan penerapan metode few-shot prompting, dirancang beberapa variasi konfigurasi prompt yang dapat dijadikan sebagai referensi untuk pengembangan prompt utama. Konfigurasi tersebut terdiri dari empat komponen fundamental:

1. **Format Template Dasar Model**

Komponen ini merupakan elemen terpenting dalam struktur template, mengingat format prompt untuk setiap Large Language Model (LLM) memiliki karakteristik yang berbeda. Seluruh konten teks prompt akan menggunakan format template dasar yang spesifik untuk masing-masing model.

2. **Identifikasi Tugas yang Dieksekusi**

Bagian ini berisi instruksi awal untuk LLM guna memahami tugas utama dalam proses klasifikasi, dilengkapi dengan deskripsi dan aturan terkait mekanisme klasifikasi, dengan adanya tujuan yang jelas, diharapkan LLM dapat langsung mendapat fokus utama dari tugas yang diberikan

3. **Aturan pada prompt**

Komponen ini memuat seperangkat aturan yang diberikan kepada LLM untuk membatasi ruang lingkup dan perilaku dalam proses klasifikasi, dengan aturan dan batasan yang jelas diharapkan LLM tidak memberikan jawaban yang terlalu general dan di luar konteks dari tugaas yang diberikan.

4. **List keyword yang digunakan**

Berisi kumpulan keyword yang langsung mengarah pada direktorat tertentu, contoh nya jika suatu kalimat mengandung kata “bayar” maka besar kemungkinan bahwa kalimat tersbeut lebih megarah ke direktorat keuangan.

5. **Contoh Teks**

contoh teks digunakan untuk memberikan contoh kalimat pada LLM bahwa kalimat tersebut masuk ke kategori direktorat mana, bagian contoh teks ini juga termasuk bagian penting pada fewshot prompting karena esensi utama dari few shot prompting adalah memberikan contoh teks yang nantinya bisa menjadi contoh untuk LLM tersebut

Dengan mengimplementasikan ke lima komponen prompt tersebut, akan dilakukan perbandingan pada setiap point dan dilakukan percobaan dengan berbagai konfigurasi. Eksperimen mencakup evaluasi penggunaan prompt secara terpisah hingga pemanfaatan seluruh point secara bersamaan.

3.2.4.4 Konfigurasi Parameter

Yang terakhir konfigurasi terhadap parameter output, berikut adalah parameter apa saja yang digunakan dalam pemrosesan klasifikasi teks menggunakan LLM:

1. n_ctx (Context Window)

Parameter n_ctx berfungsi untuk menentukan panjang konteks dalam satuan token yang dapat diproses oleh model dalam satu step. Nilai ini digunakan agar model menerima prompt dengan jumlah yang sudah ditentukan.

2. n_batch

Parameter n_batch menentukan jumlah token yang diproses dalam setiap batch selama proses inferensi. Tujuan utamanya adalah untuk mengoptimalkan efisiensi komputasi pada GPU atau CPU. Nilai n_batch yang besar (contoh: 512) dapat mempercepat proses kalsifikasi yang lebih banyak, namun memerlukan kapasitas memori yang lebih besar.

3. n_gpu_layers

Parameter n_gpu_layers digunakan untuk menentukan jumlah layer model yang dijalankan pada GPU. Pemanfaatan GPU untuk eksekusi sebagian layer dapat meningkatkan kecepatan inferensi secara signifikan dibandingkan dengan pemrosesan penuh di CPU.

4. f16_kv

Parameter f16_kv berfungsi untuk mengaktifkan penggunaan format half-precision (float16) dalam penyimpanan key/value cache pada mekanisme attention. Tujuannya adalah untuk mengurangi penggunaan memori tanpa mengurangi akurasi secara signifikan.

5. temperature

Parameter temperature mengatur tingkat tingkat keragaman dalam teks yang dihasilkan oleh model. Nilai temperature berada pada rentang 0.0 hingga 1.0. Nilai yang lebih rendah (0.2–0.4) menghasilkan keluaran yang lebih deterministik dan konsisten, sedangkan nilai yang lebih tinggi (0.8–1.0) menghasilkan keluaran yang lebih variatif.

6. top_p

Parameter top_p mengatur batas kumulatif probabilitas token yang dipertimbangkan selama proses sampling. Konsep ini dikenal sebagai nucleus sampling. Nilai top_p = 0.9 mengindikasikan bahwa hanya token-token dengan probabilitas kumulatif hingga 90% yang dipertimbangkan untuk seleksi.

7. top_k

Parameter top_k membatasi jumlah token dengan probabilitas tertinggi yang dipertimbangkan pada setiap step, atau output yang dihasilkan saat proses klasifikasi oleh model. Nilai yang rendah menghasilkan keluaran yang lebih fokus, sedangkan nilai yang tinggi meningkatkan keragaman hasil.

8. n_threads

Parameter n_threads menentukan jumlah thread CPU yang digunakan untuk komputasi paralel selama klasifikasi. Peningkatan jumlah thread dapat mempercepat proses

komputasi, namun berpotensi memberatkan CPU. Nilai n_threads = 8 mengindikasikan penggunaan delapan core CPU untuk proses klasifikasi.

9. verbose

Parameter verbose mengatur tingkat detail logging output selama prosesklasifikasi. Apabila diatur ke True, sistem akan menampilkan informasi detail mengenai proses internal.

10. use_mlock

Parameter use_mlock digunakan agar model tetap menggunkan ram utama RAM sehingga tidak menggunkaan ram kedua yang biasanya dibuat otomatis oleh OS jika ram utama sudah terlalu penuh. Tujuannya adalah untuk meningkatkan stabilitas dan kecepatan inferensi dengan menghindari latensi akses disk.

11. use_mmap

Parameter use_mmap mengaktifkan mekanisme memory mapping (mmap) selama memuat model. Teknik ini memungkinkan akses dinamis terhadap bagian-bagian model yang diperlukan, sehingga mempercepat waktu pemuatan dan mengoptimalkan penggunaan memori.

3.2.4.5 Evaluation

Evaluasi Metriks digunakan untuk mengetahui apakah output yang di hasilkan dari proses klasifikasi sudah sesuai atau belum dengan direktorat yang sudah di tentukan, ada berapa cara dalam melakukan evaluasi ini, menggunakan confusion matrix, precision, recall dan F1-score. Metrik-metrik ini dipilih karena dapat memberikan gambaran yang komprehensif terhadap kemampuan model, baik secara keseluruhan maupun per kelas, terutama dalam konteks klasifikasi multi-kelas yang tidak seimbang (imbalanced dataset). confusion matrix digunakan untuk mengetahui kebenaran label hasil klasifikasi, di jelaskan pada gambar 3.2.1, dimana TD (True Direktorat) digunakan sebagai acuan untuk menilai apakah klasifikiasi yang dihasilkan sesuai dan PD (predicted Direktorat) adalah output yang dihasilkan dari proses klasifikasi, value dari isi kolom nantinya akan berisiakn angka untuk mengetahui jumlah output yang di klasifikasikan dan apakah sudah sesuai dengan direktoratnya.

Confusion Matrix	*TD1*	*TD 2*	*TD 3*	*TD 4*	*TD 5*	*TD 6*	*TD 7*
PD 1							
PD 2							
PD 3							
PD 4							
PD 5							
PD 6							
PD 7							

Table 3.2.1 Confusion Matrix

Selanjutnya adalah penjelasan terkait metriks yang digunakan dalam mengukur performa klasifikasi yang sudah di lakukan, beberapa metriks ini nantinya akan berfungsi untuk memberikan informasi terkait keakuratan LLM dan jawaban dari setiap label yang sudah dihasilkan.

A. Akurasi (Accuracy)

Akurasi memberikan gambaran umum mengenai performa model secara keseluruhan. Namun demikian, metrik ini memiliki kelemahan pada dataset yang tidak seimbang, karena model dapat mencapai akurasi tinggi hanya dengan memprediksi label paling banyak. Oleh sebab itu, akurasi perlu dilengkapi dengan metrik lain seperti presisi, recall, dan F1-score.

B. Presisi (Precision)

Presisi mengukur tingkat ketepatan model dalam melakukan prediksi positif terhadap label tertentu. Presisi tinggi menunjukkan bahwa model jarang melakukan kesalahan dalam mengklasifikasikan data yang bukan milik kelas tersebut. Presisi digunakan untuk menilai seberapa relevan hasil prediksi model terhadap data aktual.

C. Recall (Sensitivitas)

Recall mengukur kemampuan model dalam mendeteksi seluruh data yang benar-benar termasuk ke dalam label tertentu. Nilai recall yang tinggi menunjukkan bahwa model berhasil mengklasifikasi sebagian besar data yang relevan (minim false negative).

D. F1-Score

F1-score digunakan untuk mengetahui kemampuan model dalam menghasilkan prediksi yang tepat (presisi) dan kemampuan model dalam menangkap seluruh data relevan (recall), Nilai F1-score yang tinggi menunjukkan bahwa model memiliki keseimbangan yang baik antara presisi dan recall.

3.2.4.6 Rata-rata Metrik (Averaging Method)

Pada klasifikasi multi-kelas, perhitungan presisi, recall, dan F1-score dapat dilakukan dengan tiga pendekatan utama

Weighted Average: menghitung rata-rata per kelas dengan pertimbangan berdasarkan jumlah sampel aktual (*support*) pada masing-masing label. Pendekatan ini digunakan dalam penelitian ini karena data aduan antar direktorat tidak memiliki jumlah yang seimbang, sehingga weighted average memberikan evaluasi yang lebih baik terhadap distribusi data sebenarnya.

3.2.4.7 Alasan Pemilihan Metrik

Pemilihan metrik evaluasi pada penelitian ini didasarkan pada karakteristik data dan tujuan klasifikasi, dengan pertimbangan sebagai berikut:

1. Confusion matrix digunakan untuk menganalisis pola kesalahan model dalam mengenali kategori tertentu.
2. Akurasi memberikan gambaran umum kinerja sistem.
3. Presisi penting untuk memastikan aduan tidak salah diarahkan ke direktorat yang keliru.
4. Recall penting agar sistem tidak melewatkan aduan yang seharusnya diteruskan ke direktorat terkait.

5. F1-score menjadi ukuran yang menyeimbangkan antara presisi dan recall, terutama pada dataset dengan distribusi tidak merata antar kelas.
6. Weighted average digunakan agar hasil evaluasi tidak bias terhadap kelas mayoritas.

Dengan kombinasi metrik tersebut, evaluasi performa model dapat menggambarkan kemampuan sistem secara menyeluruh dan mendalam, baik dari sisi ketepatan klasifikasi maupun pemerataan kinerja antar kategori direktorat.

3.2.5 Testing dan demonstrasi sistem

Proses diawali dengan pemrosesan teks pada modul teks processing, dilanjutkan dengan konfigurasi prompt yang diambil dari basis data, dan diakhiri dengan proses klasifikasi direktorat pada modul classify. Iterasi proses diperlukan apabila hasil akurasi yang diperoleh belum memenuhi target yang ditetapkan, sehingga konfigurasi ulang terhadap parameter dan prompt yang digunakan harus dilakukan.

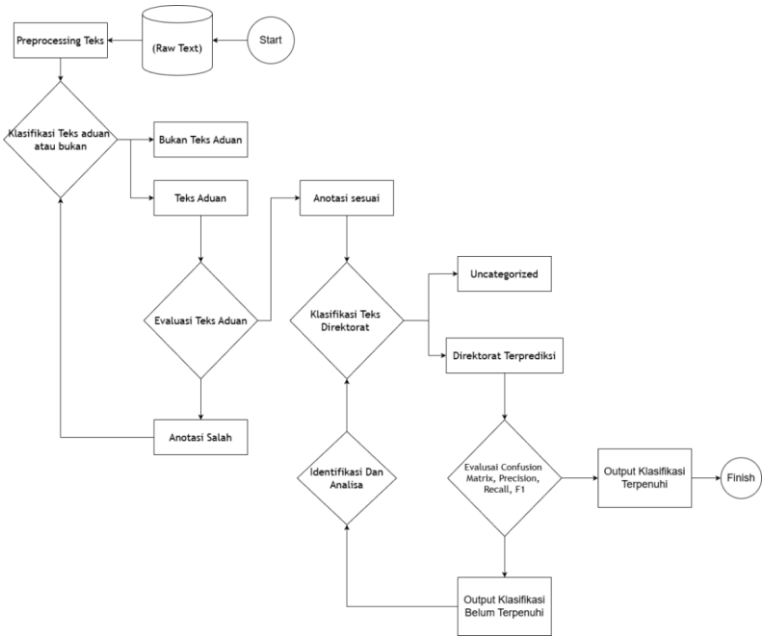

Gambar 3.2.3 Alur Proses Klasifikasi

Seperti pada gambar 3.2.1 alur proses klasifikasi digunakan sebgai acuan proses yang nantinya akan dikerjakan oleh sistem, alur disesuaikan dengan kebutuhan dan tujuan awal penelitian ini untuk klasifikasi, berikut adalah urutan sistem dari awal hingga akhir.

1. Data preparation
2. Preprocessing data
3. Klasifikasi teks aduan dan bukan
4. Evaluasi terhadap teks aduan
5. Klasifikasi Direktorat
6. Evaluasi akhir

Proses diakhiri dengan dihasilkannya output klasifikasi yang memenuhi kriteria, yang mengindikasikan bahwa data aduan telah berhasil diklasifikasikan sesuai dengan direktorat yang ditargetkan. Apabila output yang dihasilkan masih belum sesuai dengan klasifikasi aduan maupun klasifikasi direktorat, dilakukan iterasi proses melalui analisis permasalahan yang diidentifikasi, sehingga dapat dilakukan klasifikasi ulang untuk menghasilkan output yang lebih akurat dan relevan.

3.2.5.1 Skenario Pengguna

Pengguna dapat menggunakan model prompt berbasis LLM melalui web interface yang cukup mudah digunakan, pengguna hanya perlu mengunduh model yang ingin digunakan dan mengkonfigurasi prompt sesuai kebutuhan pengguna.

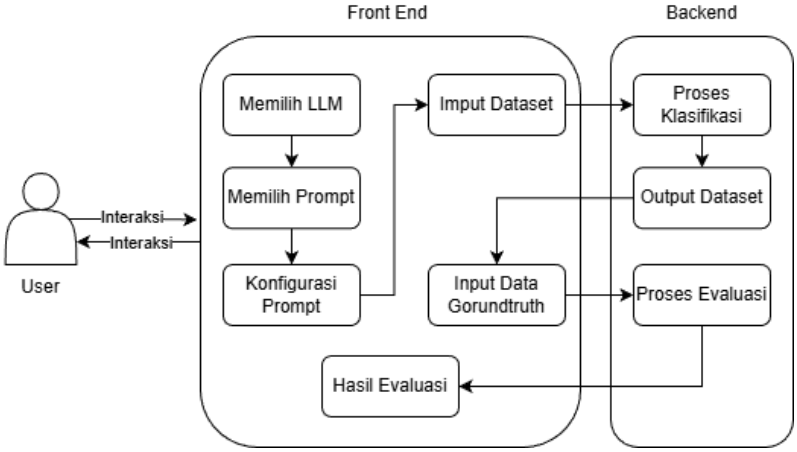

Gambar 3.2.2 Sekenario Pengguna

Pada pambar 3.2.2 ditunjukan alur pengguna menggunakan gambaran sistem untuk melakukan klasifikasi, pengguna dapat berinteraksi secara dengan bebas dengan sistem, dan melukan kustomisasi sesuai kebutuhan. Pengguna dapat memilih LLM pribadi ataupun menggunakan LLM open source, prompt yang digunakan bersifat bebas namun khusus pada penelitian ini prompt yang digunakan akan sesuai dengan konfigurasi prompt pada sub bab 3.2.4.3.

3.2.5.2 Perancangan Tampilan

Tampilan berupa webiste interface dengan beberapa menu yang dapat digunakan user untuk mengoptimalkan proses klasifikasi, dibuat untuk mempermudah user dalam melakukan konfigurasi prompt dan pemilihan LLM, web interface dibuat dengan tujuan agar user tidak kebingungan dan mempermudah ketika user ingin melakukan klasifikasi, user tidak perlu mengubah kode jika ingin mengganti dataset ataupun LLM yang digunakan, konfigurasi juga menjadi lebih mudah karena user dapat melakukan konfigurasi langung pada web interface.

1. **Menu klasifikasi**

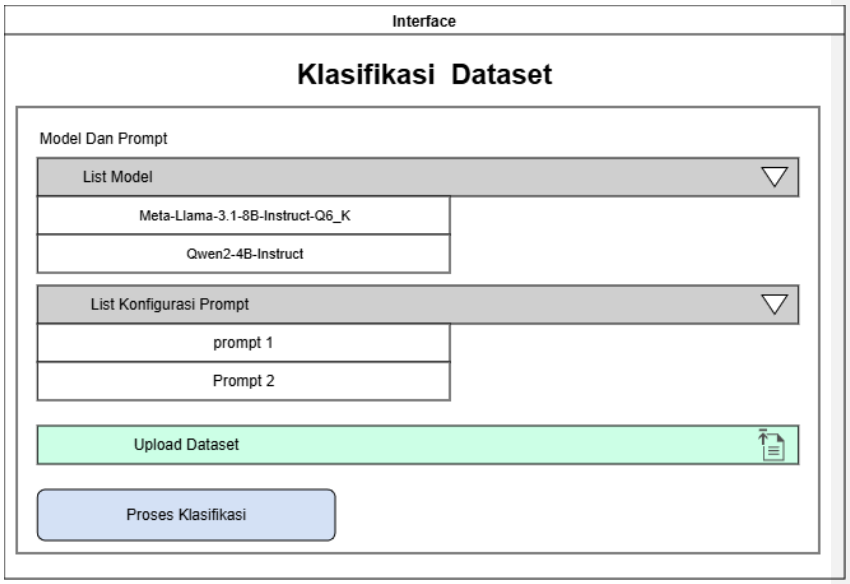

Gambar 3.2.4 Menu Klasifikasi Dataset

Pada gambar 3.2.3, menampilkan web interface pada menu klasifikasi datastset, pada interface ini user dapat memilih LLM yang digunakan untuk melakukan klasifikasi, selanjutnya user dapat memilih prompt yang telah di buat pada menu prompt manager, pada tahap selanjutnya user dapat memasukkan dataset yang ingin di klasifikasikan menggunakan interface web, output hasil klasifikasi nantinya akan otomatis dapat diunduh setelah proses klasifikasi selesai.

2. Menu prompt manager

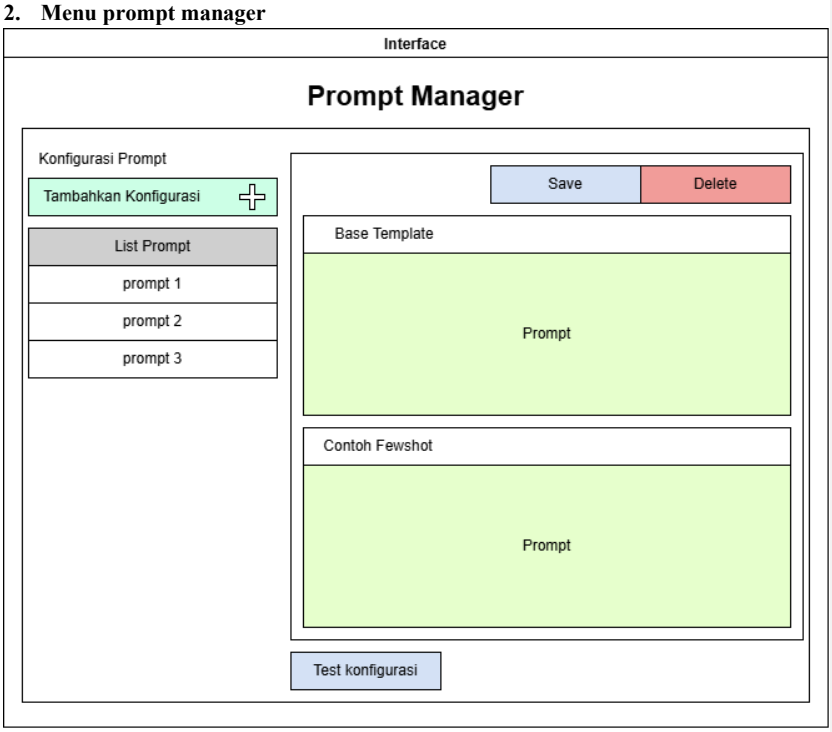

Gambar 3.2.5 Menu Prompt Manager

Pada gambar 3.2.4, merupakan rancangan tampilan dari prompt manager yang digunakan dalam mengkonfigurasi prompt yang nantinya digunakan dalam proses klasifikasi, user dapat dengan mudah melakukan konfigurasi langsung pada web interface, dengan menambah, mengurangi dan mengetes prompt secara langsung, dengan adanya interface ini, user tidak perlu lagi repot membuat file baru untuk prompt yang akan digunakan nantinya.

3. Tampilan Evaluasi

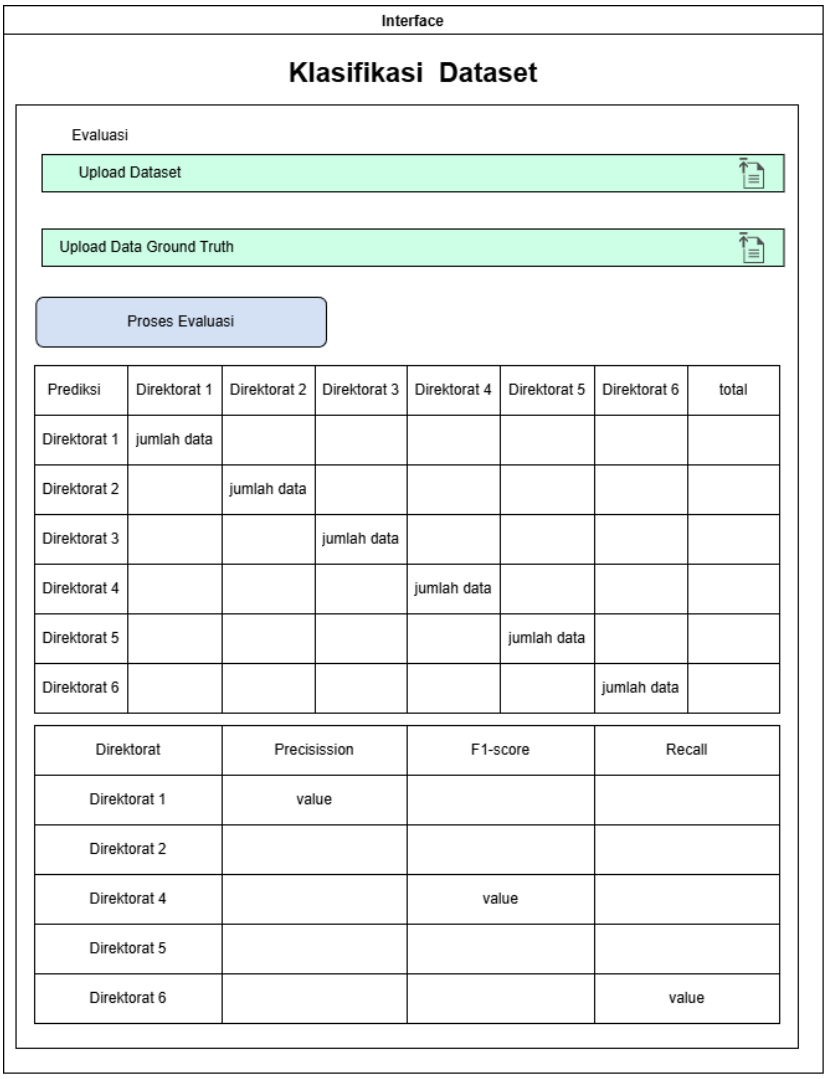

Gambar 3.2.6 Interface Evaluation

Pada gambar 3.2.5 di tampilkan interface evaluasi, interface ini digunakan untuk menilai hasil dari proses klasifikasi yang telah dilakukan oleh LLM, user dapat melihat total jumlah data yang di evaluasi dengan akurasi disetiap labelnya, dengan ini user dapat mengetahui pada label mana kesalahan dibuat, user juga dapat melihat nilai prescission dan F1-Score yang dihasilkan berdasarkan perbandingan dari data ground truth dan data dari hasil klasifikasi.

3.3 Uji Validitas Dan Realibitas

Pada subab ini akan di jelaskan metode apa untuk mengetahui tingkat kelvalitan dari data yang digunakan dan output dari hasil klasifikasi oleh sistem

3.3.1 Uji Validitas

Uji validitas bertujuan untuk mengetahui apakah data groundtruth yang digunakan sudah sesuai, dengan menanyakan langsung jawaban kepada responden yang bersangkutan dengan direktorat kampus. Dalam penelitian ini, validitas diukur berdasarkan validasi langsung dari responden dengan menanyakan kepada responden.

3.3.2 Uji Realibilitas

Uji Realibilitas bertujuan untuk menguji keakuratan klasifikasi sistem dengan melihat dengan melakukan perbandingan hasil evaluasi dengan data groundtruth, dengan ketentuan hasil akurasi diatas 85%.

3.4 Jadwal Kegiatan

Jadwal rencana pelaksanaan penelitian pada tahun 2025 dan 2026, pada tabel

Tugas 2025	Bulan ke 1	Bulan ke 2	Bulan ke 3	Bulan ke 4	Bulan ke 5	Bulan ke 6	Bulan ke 7	Bulan ke 8	Bulan ke 9	Milestone
Identifikasi Masalah										Solusi Awal Dari Permasalahan yang diangkat
Inisisasi Solusi Dan Topik										Pengajuan Topik Klasifikasi Aduan Berbasis LLM
Konsep Awal Sistem										Membuat Konsep Awal berupa model prompt untuk mengkategorikan aduan
Pembuatan Sistem										Pembuatan Sistem Berdasarkan Konsep Awal
Tahap Evaluasi										Evaluasi Output Dari Proses Klasifikasi
Penyusunan Laporan Akhir										Laporan/Buku TA

Table 3.4.1 Rencana Kegiatan

BAB IV
ANALISIS DAN HASIL PERCOBAAN

Commented [ba11]: Bab 4 sesuaikan dengan metodologi, mulai dari analisis hingga evaluasi

Pada bab ini, pembahasan berfokus pada proses pengumpulan dan pengolahan data yang sudah di peroleh yang ditujukan untuk pengembangan artefak model prompt yang akan di kembangkan, pada tahapan ini proses pengambilan data akan berfokus pada dua tahap yaitu proses pengumpulan data komentar mahasiswa dan informasi terkait setiap direktorat yang ada pada Telkom University, data yang diperoleh nantinya akan di olah dan susun untuk menyesuaikan kebutuhan proses analisis dan pengklasifikasian direktorat.

4.1. Hasil Analisis Kebutuhan

Dari hasil analisis kebutuhan yang sudah di jelaskan di bab 3, didapatkan bahwa untuk mencapai tujuan penelitian dibutuhkan sistem berbasis LLM dengan memanfaatkan prompt engineering untuk melakukan klasifikasi teks, tujuan nya adalah untuk mengkategorikan teks aduan pada akun @Telfess pada media sosial X kedalam 7 direktorat yang ada pada Telkom University sebagai acuan, untuk mencapai tujuan tersebut di dapatkan 4 komponen penting yang diperlukan dalam penelitian ini yaitu :

1. Dataset
2. LLM yang digunakan
3. Konfigurasi Prompt
4. Hasil Perbandingan dari gabungan prompt dan LLM

4.1.1 Dataset

Berupa tweet para mahasiswa yang ditulis melalui bot telyufess agar sender atau pengirim tetap anonymus, sehingga tweet yang diambil semua nya berasal dari tweet satu akun yaitu @Telfess, sehingga semua user yang mengirimkan tweet bersifat anonymus atau rahasia.

4.1.2 LLM

Pada penelitian ini digunakan LLM (Large Language Model) yang diambil dari Huggingface sehingga LLM yang digunakan bersifat lokal dan dapat diakses secara offline tanpa internet, alasan lain dari penggunakan LLM lokal ini adalah penggunaan limitasi token yang tidak terbatas sehingga tidak ketegantungan dengan token limit, pemilihan LLM akan didasarkan pada skor benchmark pada setiap model, dengan konsiderasi bahwa model tersebut memiliki skor lebih baik dibandingkan dengan model lain, hasil skor didapatkan melalui test berupa pilihan ganda yang diberikan kepada setiap model, berikut adalah penjelasan terkait benchmark yang digunakan :

Benchmark	Penjelasaan
MMLU (*Massive Multitask Language Understanding*)	Pemahaman LLM dengan bahasa lain selain bahasa utama yang digunakan oleh LLM.
CSQA (*CommonSenseQA*)	Kemampuan LLM dalam melakukan penalaran umum layaknya manusia, pemahaman terkait sebab akibat.

TriviaQA-Wiki	kemampuan LLm dalam menjawab pertanyaan berbasis pengetahuan umum.
DROP (*Discrete Reasoning Over Paragraphs*)	kemampuan model bahasa dalam melakukan penalaran berbasis teks panjang, memungkinkan LLM untuk melakukan klasifikasi teks.

Pemilihan LLM akan berdasarkan dari 4 benchmark yang sudah dijelaskan pada tabel, dengan memilih model yang memilki skor paling tinggi pada ke empat benchmark tersebut, berikut adalah list LLM yang digunakan :

1. Meta-Llama-3.1-8B-Instruct
   Llama adalah LLM yang dikembangkan oleh meta, penggunaan model Llama digunakan karena model ini memiliki keunggulan pada kemampuan *multilangual* (multi bahasa) dan dapat memahami context panjang, sehingga dapat memahami dan menghasilkan output yang sesuai dengan prompt yang sudah diberikan.

benchmark	Skor
MMLU (*Massive Multitask Language Understanding*)	66.7
CommonSenseQA	72.6
TriviaQA-Wiki	78.5
DROP	58.4

   Sumber : nvidia
2. Qwen3-4B-Instruct
   Qwen adalah model yang dibuat oleh perusahan alibaba milik china, alasan dari penggunaan model ini adalah kemampuan reasoning yang lebih unggul dari model seperti chat gpt dan gemma milik google, model ini juga mendukung pemahaman multi bahasa seperti model Llama.

benchmark	Skor
MMLU (*Massive Multitask Language Understanding*)	77
CommonSenseQA	65
TriviaQA-Wiki	70
DROP	65

   Sumber : 2505.09388
3. komodo-7b
   Komodo adalah model hasil finetuning dari model mistrail yang dikembangkan khusus untuk memahami teks bahasa indonesia, model ini dipilih karena dapat memahami bahasa indonesia lebih baik dari model llama dan qwen.

benchmark	Skor
MMLU (*Massive Multitask Language Understanding*)	65
CommonSenseQA	70
TriviaQA-Wiki	72
DROP	65

   Sumber : komodo

4.1.3 Konfigurasi Prompt

Konfigurasi prompt digunakan untuk memberikan instruksi kepada LLM secara efektif dan efisien, dengan cara merangkai prompt dengan rules dan batasan, untuk menciptakan prompt dengan efektifitas paling optimal dan dengan jumlah konteks teks paling sedikit.

4.1.3.1 Komponen Prompt

Komponen prompt memiliki peranya masing masing dengan tingkat kepentingan yang berbeda.

1. Base Template
   Berisikan teks wrapper untuk setiap LLM, setiap model memiliki wrapper yang berbeda, dibuat agar LLM dapat memahami konteks prompt yang diberikan, tanpa adanya wrapper LLM tidak dapat memahami konteks penuh dari sebuah prompt, bersifat penting.
2. Aturan
   Berisikan list instruksi yang diberikan untuk LLM, berisifat opsional.
3. Larangan
   Berisikan list larangan atau batasan yang tidak boleh LLM lakukan, bersifat opsional.
4. List direktorat
   Berisikan list dari 7 direktorat.
5. Keyword
   Berisikan kata yang sering muncul pada setiap direktorat, bersifat opsional.
6. Contoh Output
   Berisikan teks yang sudah di klasifikasikan sebagai contoh, berisfat opsional.
7. Format output
   Berisikan format output yang harus di iikuti oleh LLM, tanpa format output LLM akan memberikan output yang bias dan tidak terfokus pada output direktorat, bersifat penting.

4.1.3.2 Jenis prompt

Prompt nantinya akan dibagi menjadi 4 bagian utama yang memisahkan setiap fungsi dari prompt tersebut dengan 4 bagian utama yaitu :

1. Template prompt (teks wrapper)
2. Aturan prompt (aturan, larangan, format output)
3. Keyword list (keyword list, list direktorat)
4. Contoh output (contoh output, format output)

Jenis prompt ini nantinya akan di kombinasikan dan diubah untuk mengetahui bagaimana output dari LLM jika ada komponen prompt yang tidak lengkap atau berlebihan.

4.1.4 Hasil Perbandingan

Hasil perbandingan menjelaskan terkait evaluasi akurasi output yang dihasilkan oleh model dengan menggunakan tabel confusion metric setiap direktorat untuk mengetahui persebaran data yang dihasilkan oleh LLM seperti pada {tabel pada bab 3} , dilakukan dengan membandingkan data output dengan data groundtruth, mengetahui persentase akurasi dan jumlah teks dari setiap drektorat.

4.1.4.1 Penggunaan Library

Perhitungan evaluasi menggunakan library python :

1. Pandas
   Transformasi data memfilter data yang digunakan dan menangani missing values terhadap data yang tidak ada.
2. Sklearn.metrics
   Menangani proses perhitungan akurasi, precision, recall dan f1 score.
3. Skearn.preprocessing
   Bertujuan untuk mengubah encoding label pada tabel menjadi angka agar dapat di evaluasi.
4. Os
   Direktori file, untuk mengangi file yang diunggah untuk evaluasi.
5. Numpy
   Menangani proses perhitungan angka pada proses evaluasi.

4.1.4.2 Alur proses evaluasi

Menggambarkan alur awal proses evaluasi hingga selesai

1. Upload dataset
   Memuat dataset "approved" (ground truth/label sebenarnya) dan "not-approved" (prediksi), Mendukung format .xlsx, .xls, .csv, Menangani berbagai encoding (utf-8, latin-1, iso-8859-1, cp1252).
2. Preprocessing
   onversi nama kolom ke lowercase, Membersihkan teks: lowercase + strip (hapus spasi), Menangani nilai NaN/kosong, Identifikasi kolom direktorat dan teks secara otomatis.
3. Menyamakan teks
   Exact Match: Cari teks yang identik di kedua dataset, Partial Match: Jika tidak ada kesamaan persis, gunakan substring matching (15-30 karakter), Menggabungkan data yang cocok untuk perbandingan.
4. Kalkulasi metric
   Encode label ke angka menggunakan LabelEncoder, Hitung metrik evaluasi, Generate confusion matrix per kelas

4.1.4.3 Formula Evaluasi

Perhitungan rumus evaluasi dilakukan menggunakanmetric yang sudah dijelaskan pada bab 3 , perhitungan evaluasi menggunakan library python Sklearn.metrics untuk mengetahui output yang dihasilkan oleh LLM,

Commented [ba12]: Refer ke bab 3

metric	Rumus	Kode python
Accuracy	Total prediksi / Total sample	accuracy = float(accuracy_score(y_true_encoded, y_pred_encoded))
Precision	TP/TP+FP	precision = float(precision_score(y_true_encoded, y_pred_encoded, average='weighted', zero_division=0))
Recall	TP/TP+FN	recall = float(recall_score(y_true_encoded, y_pred_encoded, average='weighted', zero_division=0))
F1-score	2×PrecisionxRecall/Precision+Recall	f1 = float(f1_score(y_true_encoded, y_pred_encoded, average='weighted', zero_division=0))

Pengujian hasil evaluasi output akan digunakan sebagai acuan dalam penelitian ini sebagai hasil akhir, dengan menggunakanperbandingan hasil percobaan terbaik yang sudah dilakukan.

4.2. Hasil Persiapan data

Didapatkan dua tipe data yang dikumpulkan dalam proses penelitian ini, yaitu sumber data untuk klasifikasi dan sumber data untuk pembuatan prompt, data klasifikasi berupa data komentar mahasiswa sedangkan data prompt berupa data informasi direktorat terkait pada Telkom University. Yang pertama proses pemngumpulan data komentar para mahasiswa, data ini di kumpulakan melalui sosial media X telyu fess dengan menggunakan teknik crawling dengan menggunakan tools tweet harvest. Selanjutnya pengumpulan data informasi direktorat diambil melalui website resmi setiap direktorat yang ada pada webiste Telkom Direktori.

4.2.1 Data Komentar Mahasiswa

Data Diperoleh melalui satu sumber yaitu sosial media X akun Telyu Fess, pada akun ini terdapat banyak sekali komentar yang ditulis oleh mahasiswa secara anonymus, adapun data komentar yang diambil mencakup semua komentar mahasiswa dengan rentan tahun 2023 hingga tahun 2025, data komentar yang sudah diambil nantinya akan berupa file CSV dengan attribut stiap komentar berupa, jumlah favorite, tanggal post, jumlah reply, jumlah quote, jumlah retweet dan id user, data yang akan digunakan nantinya berupa komentar saja.

4.2.2 Data Informasi Direktorat

Pengumpulan data direktorat terkait akan diambil pada website resmis direktorat tersebut.

1. Direktorat Akademik
   Data yang diambil berupa data informasi terkait direktorat akademik Telkom University terkait tujuan dari direktorat tersebut, data diambil melalui webiste Direktorat Akademik.

2. Direktorat Pasca Sarjana dan Advance Learning
   Data yang diambil berasal dari website Direktorat PSAL (Pascasarjana dan *Advanced Learning*), yang merupakan salah satu Direktorat yang berada di bawah Wakil Rektor Bidang I yang memiliki wewenang dalam perencanaan dan pelaksanaan program kerja seluruh unit di Direktorat PSAL.
3. Direktorat Aset & Sustainability
   Data yang diambil brasal dari website direkorat Aset & Sustainability, yang merupakan direktorat yang berfokus pada pemeliharaan alat dan peralatan yang ada pada kampus.
4. Direktorat Keuangan
   Data yang diambil berasal dari website direktorat Keuaangan, direktorat ini mengurus segala proses transaksi, pengelolaan keuangan mahasiswa, yang mencakup mekanisme pembayaran biaya pendidikan, verifikasi transaksi, efisiensi sistem pembayaran, serta optimalisasi layanan Student Financial Services.
5. Direktorat Sumber Daya Manusia
   Data yang diambil berasal dari website direktorat Sumber Daya Manusia, Direktorat Sumber Daya Manusia berada dibawah Wakil Rektor II Bidang Sumber Daya, yang memiliki fungsi utama untuk mengelola strategi dan kebijakan perencanaan, pelaksanaan, monitoring, dan evaluasi pengembangan Sumber Daya Manusia di lingkungan Universitas Telkom.
6. Direktorat Pusat Teknologi Informasi
   Data yang diambil berasal dari webiste direktorat Pusat Teknologi Informasi, yang merupakan Direktorat yang dibawahi langsung oleh Rektor Telkom University. Direktorat PuTI (Pusat Teknologi Informasi) bertanggung jawab untuk mendukung proses bisnis lembaga sesuai visi misi Telkom University melalui layanan Teknologi Informasi. Diharapkan PuTI dapat memberikan solusi-solusi yang lebih memahami/menyesuikan kebutuhan sivitas akademik Universitas Telkom terkait penggunaan teknologi informasi di area kampus.
7. Direktorat Kemahasiswaan, Pengembangan Karir, Alumni
   Data yang diambil berasal dari webiste direktorat Kemahasiswaan, Pengembangan Karir, Alumni, yang berfungsi mengelola prestasi, kegiatan mahasiswa, pengembangan karakter, kesejahteraan mahasiswa, pengembangan Karier dan kontribusi alumni. Dengan keberadaan Direktorat KKA diharapkan seluruh mahasiswa dapat mengembangkan minat dan bakat sehingga dapat meningkatkan kompetensi khususnya dalam mempersiapkan diri dalam memasuki dunia kerja.

4.2.3 Penyusuanan Data

Ada dua jenis data pada penelitian ini, data yang belum di proses (unprocessed text) dan data yang sudah di proses (proesessed text), kedua nya didapat dengan menggunakan teknik crawling dan klassifikasi secara manual/otomatis.

4.2.3.1 Unporcessed text

Data komentar mahasiswa yang didapat melalui tweet pada akun X @telfess, dengan jumlah total 15966 komentar yang berbentuk file berupa .csv, komentar tersebut masih memiliki attribut kolom conversation_id, created_at, favourite_count, id, image_url, reply, location, tweet_count, tweet_url, user_id, dan username, komentar diambil pada

rentan tahun dari 2023 hingga 2025, dengan menggunakan eknik crawling dengan tool yang bernama tweet harvest, proses crawling dibatasi hanya pada akun @telfess tanpa menyertakan replies pengguna lain, sehingga di dapatkan komentar yang bersifat anonymous dikarenakan semua sender menggunakan satu akun yang di kirim melalui website telyu fess, dan akan di posting pada tweet akun @telfess.

4.2.3.2 Processed text

Unprocessed text yang didapatkan selanjutnya diolah dengan menggunakan teknik preprocessing data, dengan menghilangkan symbol keculai (!,?,/,.), mention dan hastag juga akan dihilangkan, selanjutnya menghapus kolom seperti kolom conversation_id, created_at, favourite_count, id, image_url, reply, location, tweet_count, tweet_url, user_id, dan username, dengan menyisakan kolom text saja.

4.2.3.3 Penyusuanan Data Ground Truth

Data Informasi ini dibuat berdasarkan acuan dari website resmi Telkom Direktori, semua data komentar dilabeli secara manual sebagai acuan benar atau salahnya hasil klasifikasi yang diahasilkan oleh LLM.

4.3. Hasil Perancangan

Diadapatkan hasil perancangan sistem berdasarkan permasalahan yang sudah dijelaskan pada bab 3, dibutuhkan sebuah system yang dapat mengidentifikasi teks aduan dan non aduan yang diberikan, dilanjutkan dengan klasifikasi direktorat, tahapan berakhir pada hasil evaluasi menggunakan data groundtruth.

4.3.1 Realisasi Arsitektur Sistem

Arsitektur sistem direalisasikan dalam bentuk aplikasi web berbasis Flask yang memisahkan fungsi antarmuka, pengendalian proses, klasifikasi, evaluasi, dan penyimpanan hasil. Pembagian modul ini dibuat agar sistem lebih mudah digunakan, dipantau, dan dikembangkan.

Visualisasi sederhana arsitektur sistem dapat digambarkan sebagai berikut:Alur Sistem :
Diagram dan penjelasan

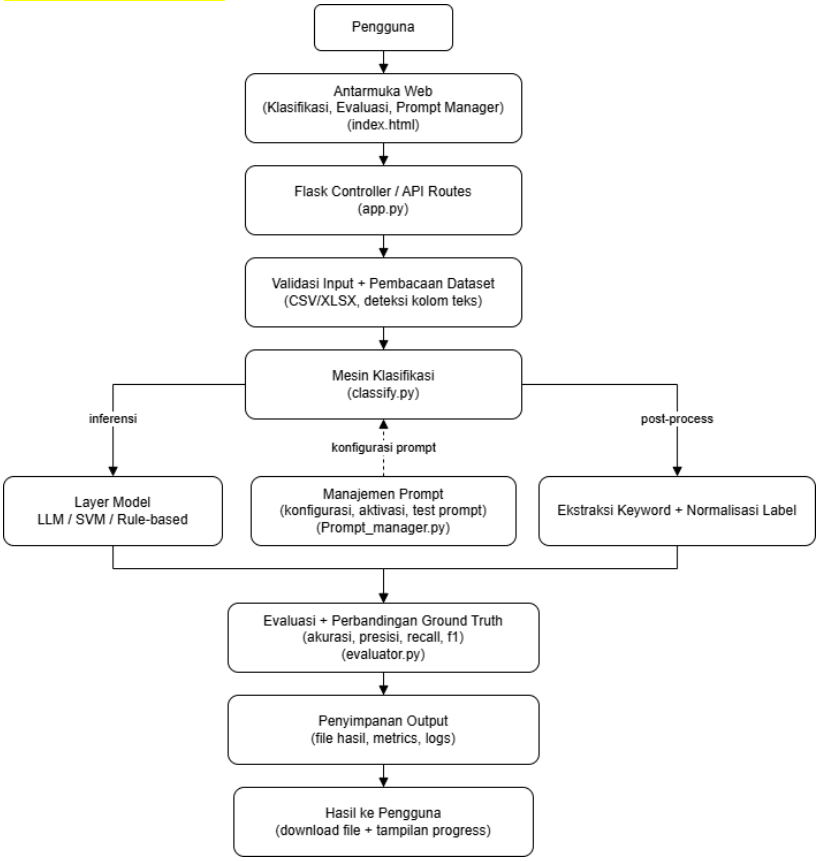

Secara teknis, sistem terdiri dari beberapa modul utama.

1. Pertama, modul antarmuka berfungsi sebagai titik interaksi pengguna untuk mengunggah dataset, memilih model, memilih mode klasifikasi, dan melihat hasil.
2. Kedua, modul controller pada Flask menerima permintaan dari antarmuka, memvalidasi input, lalu mengarahkan data ke proses klasifikasi yang sesuai.
3. Ketiga, modul klasifikasi menjalankan logika inti untuk menentukan direktorat hasil prediksi berdasarkan model yang dipilih.
4. Keempat, modul evaluasi membandingkan hasil prediksi dengan data acuan jika tersedia, kemudian menghasilkan metrik dan ringkasan performa.

5. Kelima, modul penyimpanan menyimpan hasil akhir ke file agar dapat diunduh dan dianalisis lebih lanjut.

Pembagian modul ini menunjukkan bahwa sistem dibangun sebagai banyak komponen yang saling terhubung. *Interface* hanya menangani interaksi pengguna, *controller* menangani alur permintaan, modul klasifikasi menangani inferensi, dan modul evaluasi menangani pengukuran hasil. Pemisahan ini membuat sistem lebih mudah dipahami dan lebih mudah di analisis.

4.3.2 Realisasi Antarmuka Pengguna

Tampilan pengguna pada sistem ini direalisasikan dalam bentuk aplikasi web yang dirancang agar pengguna dapat mengakses seluruh fungsi utama secara terpusat. Perancangan antarmuka menyesuaikan kebutuhan proses klasifikasi teks aduan, mulai dari pengunggahan data, pemilihan model, pengelolaan prompt, hingga penampilan hasil klasifikasi dan evaluasi. Dengan demikian, antarmuka tidak hanya berfungsi sebagai media interaksi, tetapi juga sebagai sarana pengendali proses sistem secara keseluruhan.

4.3.2.1 Main page

Halaman utama sistem menampilkan beberapa tab utama yang mewakili fungsi-fungsi inti aplikasi, yaitu tab Klasifikasi Aduan, Klasifikasi Dataset, Chat dengan AI, dan Prompt Manager. Pembagian tab ini dibuat untuk memisahkan setiap proses agar lebih mudah dipahami dan digunakan oleh pengguna. Setiap tab memiliki tujuan yang berbeda sesuai dengan tugas dari masing masing modul.

1. Tampilan Klasifikasi Dataset digunakan untuk melakukan klasifikasi direktorat terhadap dataset yang sudah berisi data aduan.
2. Tampilan rompt Manager digunakan untuk mengelola konfigurasi prompt yang dipakai pada proses klasifikasi.
3. Tampilan hasil evaluasi digunakan untuk melihat hasil akurasi dari output LLM.

4.3.2.2 Tampilan Klasifikasi Dataset

menampilkan beberapa komponen penting, yaitu pilihan mode klasifikasi, pilihan model, pemilihan konfigurasi prompt, unggah dataset, dan unggah data ground truth untuk evaluasi otomatis. Selain itu, sistem juga menyediakan indikator progres, runtime log, serta area hasil klasifikasi dan hasil perbandingan. Komponen-komponen ini dirancang agar pengguna dapat memantau jalannya proses secara langsung dan memperoleh informasi hasil secara lebih jelas. Keberadaan indikator progres dan runtime log juga membantu pengguna memahami status proses klasifikasi yang sedang berjalan.

4.3.2.3 Tampilan Prompt Manager

bagian tampilan untuk mendukung pengelolaan konfigurasi prompt secara fleksibel. Melalui fitur ini, pengguna dapat melihat, mengubah, menguji, dan mengaktifkan konfigurasi prompt yang digunakan sistem. Fitur ini penting karena kualitas hasil klasifikasi sangat dipengaruhi oleh susunan prompt yang digunakan pada model. Dengan adanya tampilan ini, proses pengaturan prompt dapat dilakukan tanpa perlu mengubah kode program utama.

4.3.2.4 Tampilan Evaluasi

Antarmuka ini digunakan untuk melihat hasil perbandingan antara data yang dihasilkan oleh LLM dengan datagroundtruth yang sudah diklasifikasi secara manual, fitur ini digunakan sebagai pengukur dalam menilai output yang dihasilkan oleh LLM, dengan adanya tampilan ini persebaran data dapat dilihat dan dapat dievaluasi untuk meningkatkan akurasi.

4.3.3 Realisasi Proses Klasifikasi

Realisasi proses klasifikasi pada penelitian ini disusun sebagai implementasi langsung dari rancangan sistem yang telah dijabarkan pada bab sebelumnya. Fokus pembahasan pada subbab ini tidak mengulang landasan metodologis, melainkan menekankan bagaimana alur klasifikasi diwujudkan dalam sistem operasional yang dapat digunakan oleh pengguna melalui antarmuka web. Dengan pendekatan tersebut, proses klasifikasi tidak hanya dipandang sebagai mekanisme komputasi, tetapi sebagai rangkaian layanan yang mencakup validasi masukan, pemrosesan data, inferensi model, hingga penyajian keluaran yang siap dianalisis.

Secara konseptual, proses klasifikasi dibangun dengan prinsip pemisahan tanggung jawab antar-tahap agar setiap tahap dapat dikendalikan, dipantau, dan dievaluasi secara terukur. Tahap pertama berfungsi menerima masukan pengguna berupa dataset dan parameter klasifikasi. Tahap kedua melakukan pemeriksaan kelayakan data agar tidak terjadi kegagalan proses pada tahap inferensi. Tahap ketiga menjalankan klasifikasi inti berdasarkan mode yang dipilih, lalu menghasilkan label prediksi untuk setiap entri data. Tahap keempat menyusun keluaran akhir dalam format yang dapat diunduh serta menampilkan ringkasan hasil pada antarmuka sistem.

Implementasi proses klasifikasi juga mempertimbangkan kebutuhan praktis pengguna, khususnya saat menangani volume data yang besar. Oleh karena itu, sistem menyediakan mekanisme pemantauan proses secara progresif melalui indikator status dan catatan log eksekusi. Mekanisme ini penting untuk menjaga transparansi proses, mengurangi ketidakpastian pengguna selama eksekusi, serta mempermudah identifikasi kendala ketika terjadi ketidaksesuaian input atau anomali hasil.

4.3.3.1 Tahap awal realisasi proses klasifikasi

dilakukan pada fungsi utama yang mengatur orkestrasi keseluruhan proses, yaitu classify.py. Pada fungsi ini, sistem menentukan mode klasifikasi, memvalidasi berkas

input, membaca data, menemukan kolom teks, melakukan praproses, memuat model, menjalankan loop inferensi, dan menyimpan hasil klasifikasi.

```
function klasifikasi_dataset(file_input, model, mode, config_prompt=None,
ground_truth=None):
  dataset <- baca_file(file_input)
  validasi(dataset)
  kolom_teks <- identifikasi_kolom_teks(dataset)

  hasil <- empty_list
  log_proses <- empty_list

  for setiap baris in dataset:
    teks <- baris[kolom_teks]
    teks_bersih <- preprocessing(teks)

    if teks_bersih kosong:
      prediksi <- ("Akademik", "-")
    else if mode == "fast_mode":
      prediksi <- klasifikasi_heuristik_dan_model(teks_bersih, model, config_prompt)
    else if mode == "pure_llm":
      prediksi <- klasifikasi_murni_model(teks_bersih, model, config_prompt)
    else:
      prediksi <- klasifikasi_default(teks_bersih, model, config_prompt)

    prediksi <- normalisasi_label(prediksi)
    prediksi <- validasi_keyword_terhadap_teks(prediksi, teks_bersih)
  return hasil
```

4.3.3.2 Fungsi Preprocessing Teks

Fungsi ini berperan penting dalam menormalkan bentuk teks agar lebih konsisten sebelum inferensi dilakukan. Fungsi ini merealisasikan validasi format keluaran model, normalisasi label direktorat, serta pembersihan keyword agar output akhir tetap konsisten.

```
function proses_satu_teks(teks, model, mode, config_prompt):
   if teks kosong:
      return ("Akademik", "-")

   if mode == "fast_mode":
      hasil_heuristik <- cek_heuristik_cepat(teks)
      if hasil_heuristik tersedia:
         return hasil_heuristik

   prompt <- bangun_prompt(teks, config_prompt)
   prompt <- tambahkan_format_jawaban_ketat(prompt)
   prompt <- sesuaikan_prompt_dengan_model(prompt, model)

   output <- inferensi_model(model, prompt)

   if output kosong:
      output <- retry_inferensi(model, prompt)

   if output tetap kosong:
      return ("Akademik", "-")

   direktorat, keyword <- parse_hasil_model(output, teks)
   direktorat, keyword <- validasi_prediksi_dengan_teks(direktorat, keyword, teks)

   return (direktorat, keyword)
```

4.3.3.3 Fungsi parsing hasil model

Bagian ini menunjukkan bagaimana output model diubah menjadi format yang sesuai. Fungsi ini memastikan output model sesuai format yang diharapkan. Jika model menghasilkan format yang tidak konsisten, sistem tetap mencoba menormalkan hasilnya, Jika direktorat tidak terdeteksi, sistem memberi nilai default agar proses tidak berhenti. Ini penting untuk menjaga stabilitas hasil klasifikasi.

```
function parse_hasil_model(output, teks_asli):
    direktorat <- null
    keyword <- "-"

    if parser_improved_tersedia:
        direktorat, keyword <- parser_improved(output, teks_asli)
        return (direktorat, keyword)

    daftar_valid <- [
        "Akademik",
        "Pasca Sarjana dan Advance Learning",
        "Aset & Sustainability",
        "Keuangan",
        "Sumber Daya Manusia",
        "Pusat Teknologi Informasi",
        "Kemahasiswaan, Pengembangan Karir, Alumni"
    ]

    kandidat <- ekstrak_dengan_pola_regex(output)

    for setiap item in kandidat:
        dir_kandidat <- normalisasi_direktorat(item.direktorat)
        key_kandidat <- bersihkan_keyword(item.keyword)

        if dir_kandidat ada dalam daftar_valid:
            direktorat <- dir_kandidat
            keyword <- key_kandidat
            break

    if direktorat belum ditemukan:
        direktorat <- infer_direktorat_dari_mention(output)

    if direktorat belum ditemukan dan teks_asli tersedia:
        direktorat <- infer_direktorat_dari_teks(teks_asli)

    if direktorat belum ditemukan:
        direktorat <- "Akademik"

    keyword <- bersihkan_keyword(keyword)
    return (direktorat, keyword)
```

4.3.3.4 Fungsi Validasi keyword

Tahap ini memastikan bahwa keyword yang disimpan benar-benar memiliki keterkaitan dengan teks hasil praproses, Fungsi ini mengecek apakah keyword benar-benar muncul

di teks, Kalau tidak ada keyword yang cocok, sistem memberi tanda -. Tujuannya agar hasil akhir lebih valid dan tidak asal menghasilkan keyword.

```
function validasi_keyword(df_hasil):
    keyword_final <- empty_list

    for setiap baris in df_hasil:
        teks_bersih <- baris.processed_text
        keyword_raw <- baris.Keyword

        if keyword_raw kosong atau keyword_raw == "-":
            keyword_final.append("-")
            continue

        kandidat_keyword <- pecah_keyword_menjadi_kandidat(keyword_raw)
        dipilih <- null

        for setiap kandidat in kandidat_keyword:
            if kandidat_muncul_di_teks(teks_bersih, kandidat):
                dipilih <- kandidat
                break

        if dipilih tersedia:
            keyword_final.append(dipilih)
        else:
            keyword_final.append("-")

    df_hasil.Keyword <- keyword_final
    return df_hasil
```

Dari sisi kualitas implementasi, realisasi proses klasifikasi pada sistem ini memperlihatkan tiga karakteristik utama. Pertama, konsistensi alur, yaitu adanya urutan proses yang tetap dari masukan hingga keluaran, sehingga proses dapat direplikasi pada skenario data yang berbeda. Kedua, keterlacakan proses, yaitu kemampuan sistem menampilkan status eksekusi yang memudahkan pemantauan dan penelusuran kesalahan. Ketiga, adaptivitas eksekusi, yaitu dukungan terhadap lebih dari satu mode klasifikasi untuk menyesuaikan kebutuhan antara kecepatan proses dan ketelitian prediksi.

4.3.4 Realisasi Fitur Evaluasi

Fitur evaluasi pada sistem ini direalisasikan untuk mengukur kualitas hasil klasifikasi yang dihasilkan oleh sistem. Evaluasi dilakukan agar hasil prediksi tidak hanya ditampilkan sebagai keluaran akhir, tetapi juga dapat dibandingkan dengan data acuan sehingga performa sistem dapat diketahui secara lebih objektif. Dengan demikian, fitur evaluasi menjadi bagian penting dalam memastikan bahwa sistem yang dibangun tidak hanya berfungsi secara operasional, tetapi juga dapat dinilai secara kuantitatif.

Realisasi fitur evaluasi, klasifikasi dilakukan, apabila ground truth atau data acuan tersedia. Bentuk kedua adalah perbandingan independen antara dua dataset, yaitu dataset hasil prediksi dan dataset yang telah memiliki label benar (groundtruth). Kedua bentuk evaluasi tersebut dirancang untuk memberikan fleksibilitas dalam menilai hasil klasifikasi sesuai kebutuhan pengguna.

4.3.4.1 Realisasi Alur Evaluasi Utama

Alur evaluasi direalisasikan melalui fungsi utama yang mengorkestrasi proses pemuatan data, praproses, penyelarasan pasangan data aktual-prediksi, dan perhitungan metrik.

```
def evaluate(self, approved_path, not_approved_path):
    """Main evaluation function"""
    try:
        print("Loading datasets...")
        approved_df, not_approved_df = self.load_datasets(approved_path, not_approved_path)

        print("Preprocessing datasets...")
        approved_df, not_approved_df = self.preprocess_datasets(approved_df, not_approved_df)

        print("Aligning datasets...")
        matched_df = self.align_datasets(approved_df, not_approved_df)

        print("Calculating metrics...")
        metrics = self.calculate_metrics(matched_df)

        return metrics

    except Exception as e:
        raise Exception(f"Evaluation failed: {str(e)}")
```

proses evaluasi bersifat end-to-end dan terdokumentasi dalam satu alur kerja yang konsisten. Struktur ini memudahkan pelacakan proses evaluasi serta menjaga konsistensi keluaran evaluasi pada berbagai skenario pengujian.

4.3.4.2 Realisasi Perhitungan Metrik Keseluruhan

Perhitungan metrik evaluasi dilakukan dengan membandingkan label hasil prediksi terhadap label sebenarnya pada ground truth. Jika data acuan tersedia, sistem akan menghitung tingkat kesesuaian hasil klasifikasi dengan label yang benar. Proses ini menghasilkan beberapa metrik utama, yaitu akurasi, presisi, recall, dan F1-score.

Setelah data aktual dan prediksi terselaraskan, sistem menghitung metrik evaluasi global, yaitu accuracy, precision, recall, dan F1-score.

```
y_true = matched_df['actual_direktorat']
y_pred = matched_df['predicted_direktorat']

all_labels = sorted(set(y_true) | set(y_pred))
label_mapping = {label: idx for idx, label in enumerate(all_labels)}

y_true_encoded = np.array([label_mapping[label] for label in y_true])
y_pred_encoded = np.array([label_mapping[label] for label in y_pred])

accuracy = float(accuracy_score(y_true_encoded, y_pred_encoded))
precision = float(precision_score(y_true_encoded, y_pred_encoded, average='weighted',
zero_division=0))
recall = float(recall_score(y_true_encoded, y_pred_encoded, average='weighted', zero_division=0))
f1 = float(f1_score(y_true_encoded, y_pred_encoded, average='weighted', zero_division=0))
```

Implementasi ini menunjukkan bahwa sistem menggunakan pendekatan perhitungan metrik terstandar berbasis library evaluasi, dengan penanganan kasus pembagian nol melalui parameter zero_division agar proses tetap stabil.

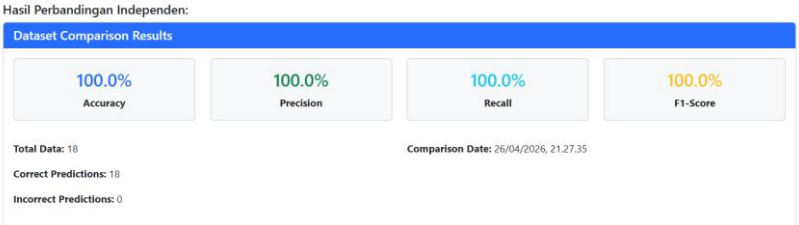

Akurasi digunakan untuk menunjukkan persentase prediksi yang benar dari seluruh data yang diuji. Presisi digunakan untuk melihat ketepatan hasil prediksi pada kelas tertentu, sedangkan recall menunjukkan kemampuan sistem dalam menemukan seluruh data yang seharusnya termasuk dalam kelas tersebut. F1-score digunakan sebagai ukuran gabungan antara presisi dan recall, sehingga dapat memberikan gambaran yang lebih seimbang mengenai performa sistem.

4.3.4.3 Hasil Perhitungan Metrik Evaluasi

Selain metrik utama, sistem juga dapat menghasilkan confusion matrix. Confusion matrix digunakan untuk memperlihatkan hubungan antara label aktual dan label prediksi, sehingga kesalahan klasifikasi dapat dianalisis lebih lanjut. Dengan adanya confusion matrix, pengguna dapat mengetahui kelas mana yang paling sering tertukar dan bagian mana yang perlu ditingkatkan.

```
class_metrics = {}
for label in all_labels:
    true_positives = int(len(matched_df[
        (matched_df['actual_direktorat'] == label) &
        (matched_df['predicted_direktorat'] == label)
    ]))
    false_positives = int(len(matched_df[
        (matched_df['actual_direktorat'] != label) &
        (matched_df['predicted_direktorat'] == label)
    ]))
    false_negatives = int(len(matched_df[
        (matched_df['actual_direktorat'] == label) &
        (matched_df['predicted_direktorat'] != label)
    ]))

    precision_class = float(true_positives / (true_positives + false_positives)) if (true_positives +
false_positives) > 0 else 0.0
    recall_class = float(true_positives / (true_positives + false_negatives)) if (true_positives +
false_negatives) > 0 else 0.0
    f1_class = float(2 * (precision_class * recall_class) / (precision_class + recall_class)) if (precision_class
+ recall_class) > 0 else 0.0
```

Melalui perhitungan ini, sistem dapat menghasilkan laporan detail per kelas yang berguna untuk identifikasi kelas yang kuat maupun kelas yang masih memerlukan peningkatan pada tahap pengembangan berikutnya.

Confusion Matrix

Actual \ Predicted	Akademik	Aset & Sustainability	Kemahasiswaan, Pengembangan Karir, Alumni	Keuangan	Pasca Sarjana dan Advance Learning	Pusat Teknologi Informasi	Sumber Daya Manusia	Total
Akademik	3	0	0	0	0	0	0	3
Aset & Sustainability	0	2	0	0	0	0	0	2
Kemahasiswaan, Pengembangan Karir, Alumni	0	0	5	0	0	0	0	5
Keuangan	0	0	0	3	0	0	0	3
Pasca Sarjana dan Advance Learning	0	0	0	0	1	0	0	1
Pusat Teknologi Informasi	0	0	0	0	0	3	0	3
Sumber Daya Manusia	0	0	0	0	0	0	1	1

4.3.4.4 Interpretasi Hasil Evaluasi

Hasil evaluasi yang diperoleh dari sistem digunakan untuk menilai sejauh mana rancangan klasifikasi telah berhasil direalisasikan. Jika nilai metrik menunjukkan hasil yang tinggi, maka sistem dapat dikatakan mampu melakukan klasifikasi dengan baik. Sebaliknya, jika terdapat kelas yang memiliki nilai evaluasi lebih rendah, maka hal tersebut menunjukkan adanya kemungkinan ketidaktepatan dalam proses klasifikasi pada kelas tertentu.

Dari hasil evaluasi juga dapat diketahui apakah sistem cenderung lebih baik dalam mengenali kelas tertentu dibandingkan kelas lainnya. Informasi ini penting untuk menjadi dasar pengembangan lanjutan, baik pada tahap perbaikan prompt, penyesuaian

model, maupun penyempurnaan aturan klasifikasi. Dengan demikian, fitur evaluasi tidak hanya berfungsi sebagai alat ukur, tetapi juga sebagai dasar analisis untuk peningkatan kualitas sistem.

Detailed Classification Report

Class	Precision	Recall	F1-Score	Support
Akademik	100.0%	100.0%	100.0%	3
Aset & Sustainability	100.0%	100.0%	100.0%	2
Kemahasiswaan, Pengembangan Karir, Alumni	100.0%	100.0%	100.0%	5
Keuangan	100.0%	100.0%	100.0%	3
Pasca Sarjana dan Advance Learning	100.0%	100.0%	100.0%	1
Pusat Teknologi Informasi	100.0%	100.0%	100.0%	3
Sumber Daya Manusia	100.0%	100.0%	100.0%	1

Berdasarkan realisasi tersebut, dapat disimpulkan bahwa fitur evaluasi telah berhasil diimplementasikan dalam sistem klasifikasi teks aduan. Fitur ini memberikan kemampuan kepada sistem untuk menampilkan hasil prediksi sekaligus mengukur performanya secara kuantitatif, sehingga hasil klasifikasi menjadi lebih dapat dipertanggungjawabkan.

4.3.5 Realisasi Manajemen Prompt

Subbab ini membahas implementasi fitur manajemen prompt yang digunakan untuk mengelola konfigurasi prompt secara terpusat melalui basis data. Realisasi fitur ini mencakup aspek antarmuka pengguna, struktur data, serta alur operasional pengelolaan konfigurasi. Dengan pendekatan tersebut, pengguna dapat melakukan penyesuaian prompt tanpa mengubah kode program utama, sehingga proses eksperimen dan peningkatan kualitas klasifikasi dapat dilakukan secara lebih fleksibel.

4.3.5.1 Realisasi Tampilan Prompt Manager

Tampilan Prompt Manager direalisasikan sebagai antarmuka khusus untuk pengelolaan konfigurasi prompt. Pada tampilan ini, pengguna dapat melihat daftar konfigurasi yang tersedia, status konfigurasi aktif, serta komponen penyusun prompt pada setiap konfigurasi. Komponen yang dikelola meliputi bagian base, instructions, keywords, dan examples.

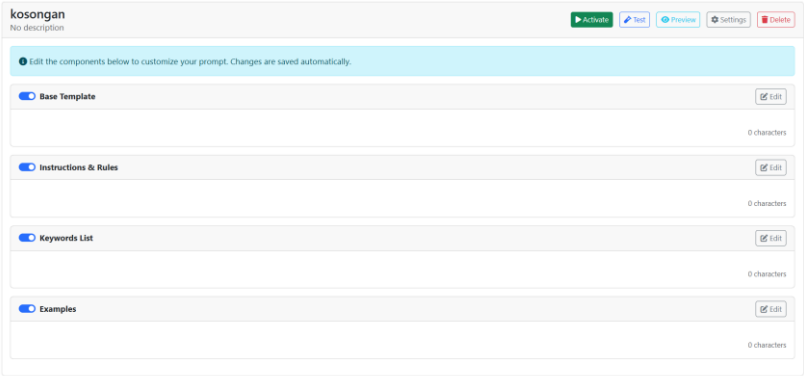

Selain menampilkan data konfigurasi, antarmuka juga menyediakan fasilitas untuk membuat konfigurasi baru, menyalin konfigurasi dari data yang sudah ada, memperbarui isi komponen, serta menguji konfigurasi sebelum digunakan pada proses klasifikasi utama. Dengan demikian, tampilan Prompt Manager berfungsi tidak hanya sebagai media administrasi data, tetapi juga sebagai sarana validasi operasional terhadap rancangan prompt yang akan diterapkan.

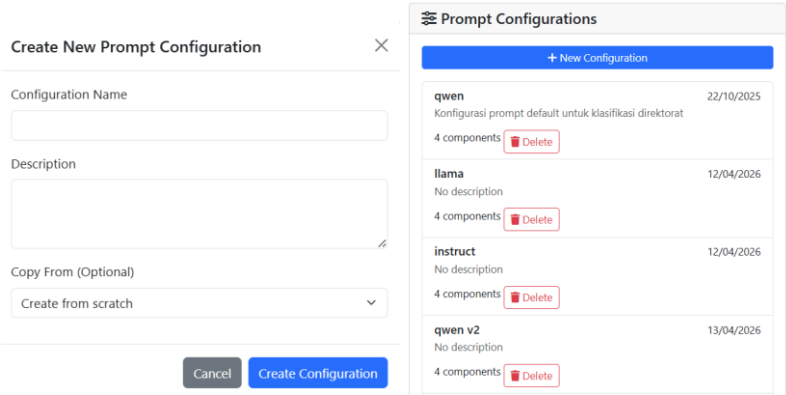

Secara fungsional, realisasi tampilan ini mendukung prinsip kemudahan penggunaan karena pengguna dapat melakukan seluruh proses pengelolaan prompt melalui antarmuka web tanpa kebutuhan intervensi langsung pada level kode.

4.3.5.2 Realisasi Operasi Create dan Read

Realisasi manajemen prompt pada sistem menerapkan alur CRUD (Create, Read, Update, Delete) yang terhubung dengan basis data melalui ORM SQLAlchemy.

Operasi Create digunakan untuk menambahkan konfigurasi prompt baru ke basis data. Dari sisi antarmuka, proses diawali saat pengguna mengisi nama konfigurasi, deskripsi,

dan opsi penyalinan dari konfigurasi yang sudah ada. Data tersebut dikirim ke endpoint POST /api/prompt-configs di app.py, lalu diproses oleh metode create_new_config pada prompt_manager.py.

Pada tahap Create, pengguna dapat membuat konfigurasi prompt baru, baik dari konfigurasi kosong maupun hasil penyalinan konfigurasi yang sudah tersedia.

```
@app.route('/api/prompt-configs', methods=['POST'])
def create_prompt_config():
    data = request.json
    new_config = prompt_manager.create_new_config(
        name=data['name'],
        description=data.get('description', ''),
        copy_from=data.get('copy_from')
    )
    return jsonify({'id': new_config.id, 'message': 'Configuration created'})
```

Dari sisi service, proses create diimplementasikan dengan membuat entitas konfigurasi baru dan menyalin komponen dari konfigurasi sumber, Secara teknis, sistem membuat record baru pada entitas PromptConfig, kemudian melakukan flush untuk memperoleh id konfigurasi baru. Setelah itu, sistem menyalin komponen dari konfigurasi sumber (copy_from) atau dari konfigurasi aktif/default. Setiap komponen disimpan sebagai record baru pada PromptComponent dengan config_id yang merujuk ke konfigurasi baru. Proses diakhiri dengan commit agar perubahan tersimpan permanen.

```
def create_new_config(self, name: str, description: str = "", copy_from: Optional[int] = None) ->
PromptConfig:
    new_config = PromptConfig(name=name, description=description, is_active=False)
    db.session.add(new_config)
    db.session.flush()
    ...
    db.session.commit()
    return new_config
```

Operasi Read direalisasikan dalam dua proses:

1. Pembacaan daftar konfigurasi (GET /api/prompt-configs).

```
@app.route('/api/prompt-configs', methods=['GET'])
def get_prompt_configs():
    configs = PromptConfig.query.all()
    return jsonify([{
        'id': config.id,
        'name': config.name,
        'description': config.description,
        'is_active': config.is_active,
        'created_at': config.created_at.isoformat(),
        'component_count': len(config.components)
    } for config in configs])
```

2. Pembacaan detail konfigurasi tertentu (GET /api/prompt-configs/{config_id}).

```
@app.route('/api/prompt-configs/<int:config_id>', methods=['GET'])
def get_prompt_config(config_id):
    config = PromptConfig.query.get_or_404(config_id)
    components = prompt_manager.get_config_components(config_id)
    return jsonify({
        'config': {...},
        'components': [...]
    })
```

Endpoint daftar mengembalikan informasi ringkas seperti id, name, description, is_active, tanggal pembuatan, serta jumlah komponen. Endpoint detail mengembalikan metadata konfigurasi dan seluruh komponen prompt, termasuk tipe komponen, isi konten, status aktif, dan urutan komponen.

hasil operasi read ini digunakan untuk:

1. Menampilkan daftar konfigurasi di panel kiri.
2. Memuat editor konfigurasi pada panel utama.
3. Menentukan status visual konfigurasi aktif.
4. Menyediakan data awal untuk proses edit, preview, test, atau delete.

Dengan demikian, operasi Read menjadi fondasi sinkronisasi data antara database dan tampilan pengguna.

4.3.5.3 Realisasi Operasi Update

Operasi Update pada manajemen prompt direalisasikan pada dua level, yaitu pembaruan metadata konfigurasi dan pembaruan komponen prompt.

Operasi Update pada sistem dibagi menjadi dua jenis utama:

1. Update metadata konfigurasi (PUT /api/prompt-configs/{config_id}).

```
@app.route('/api/prompt-configs/<int:config_id>', methods=['PUT'])
def update_prompt_config(config_id):
    data = request.get_json()
    config = PromptConfig.query.get(config_id)
    if name:
        config.name = name
    if description is not None:
        config.description = description
    config.updated_at = datetime.utcnow()
    db.session.commit()
    return jsonify({'message': 'Configuration updated successfully'})
```

Update metadata digunakan untuk mengubah nama dan deskripsi konfigurasi. Sistem memvalidasi keberadaan data JSON dan memastikan konfigurasi yang dituju tersedia

sebelum perubahan disimpan. Timestamp updated_at juga diperbarui sebagai jejak perubahan.

2. Update komponen prompt (PUT /api/prompt-components/{component_id}).

```
@app.route('/api/prompt-components/<int:component_id>', methods=['PUT'])
def update_prompt_component(component_id):
    data = request.get_json()
    prompt_manager.update_component(
        component_id=component_id,
        content=data.get('content'),
        is_enabled=data.get('is_enabled')
    )
    return jsonify({'message': 'Component updated successfully'})
```

Update komponen digunakan untuk mengubah isi konten prompt (content) serta status aktif/nonaktif komponen (is_enabled). Pada antarmuka, perubahan ini dapat terjadi melalui modal editor komponen maupun tombol switch toggle komponen. Dari sisi backend, perubahan dikelola melalui metode update_component di prompt_manager.py, lalu disimpan dengan transaksi database.

Pada frontend, perubahan komponen dilakukan melalui pemanggilan API PUT

```
function saveComponentChanges() {
    fetch(`/api/prompt-components/${componentId}`, {
        method: 'PUT',
        headers: { 'Content-Type': 'application/json' },
        body: JSON.stringify({ content: content, is_enabled: isEnabled })
    })
}
```

fungsi dari operasi Update adalah:

1. Pengguna dapat menyesuaikan kualitas prompt secara cepat.
2. Eksperimen prompt menjadi lebih fleksibel.
3. Konfigurasi tetap terdokumentasi dengan status perubahan terbaru

4.3.5.4 Realisasi Operasi Delete

Operasi Delete direalisasikan melalui endpoint DELETE /api/prompt-configs/{config_id} di app.py. Proses penghapusan tidak dilakukan secara bebas, melainkan melewati validasi proteksi:

1. Konfigurasi aktif tidak boleh dihapus.
2. Konfigurasi default tidak boleh dihapus.
3. Konfigurasi harus benar-benar ada di database.

```
@app.route('/api/prompt-configs/<int:config_id>', methods=['DELETE'])
def delete_prompt_config(config_id):
    config = PromptConfig.query.get(config_id)
    if config.is_active:
        return jsonify({'error': 'Cannot delete active configuration...'}), 400
    if config.name == 'Default Config':
        return jsonify({'error': 'Cannot delete default configuration'}), 400
    db.session.delete(config)
    db.session.commit()
    return jsonify({'message': f'Configuration \"{config_name}\" deleted successfully'})
```

Apabila validasi lolos, sistem menjalankan penghapusan record konfigurasi. Karena relasi komponen menggunakan cascade='all, delete-orphan' pada model, data komponen terkait ikut terhapus secara otomatis saat konfigurasi induk dihapus. Mekanisme ini menjaga konsistensi data dan mencegah orphan records.

Hasil operasi Delete adalah berkurangnya konfigurasi yang tidak diperlukan tanpa merusak integritas data utama sistem..

4.3.5.5 Realisasi Aktivasi Konfigurasi Prompt

Selain alur CRUD, sistem menyediakan mekanisme aktivasi konfigurasi yang berfungsi menentukan prompt aktif yang digunakan pada proses klasifikasi. Mekanisme ini dirancang agar hanya satu konfigurasi berstatus aktif pada satu waktu. Ketika pengguna mengaktifkan konfigurasi baru, sistem akan menonaktifkan konfigurasi aktif sebelumnya secara otomatis, kemudian menyimpan status aktif terbaru ke basis data. Pendekatan ini menjaga konsistensi pemanggilan prompt pada proses klasifikasi dan mencegah konflik antar konfigurasi.

Operasi Activate direalisasikan melalui endpoint POST /api/prompt-configs/{config_id}/activate. Tujuan operasi ini adalah menetapkan satu konfigurasi prompt sebagai konfigurasi aktif yang dipakai oleh proses klasifikasi.

Mekanisme aktivasi pada prompt_manager.py dilakukan dalam dua tahap:

1. Menonaktifkan semua konfigurasi (is_active = False).

```
def activate_config(self, config_id: int):
    PromptConfig.query.update({PromptConfig.is_active: False})
    config = PromptConfig.query.get(config_id)
    if config:
        config.is_active = True
        db.session.commit()
```

Endpoint aktivasi:

```
@app.route('/api/prompt-configs/<int:config_id>/activate', methods=['POST'])
def activate_prompt_config(config_id):
    prompt_manager.activate_config(config_id)
    return jsonify({'message': 'Configuration activated'})
```

2. Mengaktifkan konfigurasi terpilih (is_active = True), lalu commit.

```
function activateConfig(configId) {
    fetch(`/api/prompt-configs/${configId}/activate`, { method: 'POST' })
        .then(() => {
            loadConfigurations();
            if (currentConfigId === configId) {
                loadConfigEditor(configId);
            }
        });
}
```

Fungsi dari operasi Activate ini adalah:

1. Konsistensi prompt yang dipakai sistem saat runtime.
2. Mencegah konflik antar konfigurasi.
3. Mempermudah kontrol eksperimen prompt berbasis skenario aktif.

Secara keseluruhan, alur CRUD dan aktivasi konfigurasi prompt telah direalisasikan dengan baik karena mendukung pengelolaan konfigurasi secara dinamis, terstruktur, dan terdokumentasi, serta selaras dengan kebutuhan pengujian dan optimasi sistem klasifikasi.

4.3.5.6 Database Manajemen Prompt

Pada implementasi database manajemen prompt, relasi antar atribut dibangun menggunakan konsep primary key dan foreign key. Tabel PromptConfig berfungsi sebagai tabel utama yang menyimpan informasi konfigurasi prompt, seperti nama konfigurasi, deskripsi, status aktif, serta informasi waktu pembuatan dan pembaruan. Pada tabel ini, atribut id digunakan sebagai primary key yang menjadi identitas unik bagi setiap konfigurasi prompt.

Selanjutnya, tabel PromptComponent digunakan untuk menyimpan komponen-komponen penyusun prompt, seperti base, instructions, keywords, dan examples. Setiap data pada tabel ini memiliki atribut config_id sebagai foreign key yang mereferensikan atribut id pada tabel PromptConfig. Relasi tersebut menunjukkan bahwa satu konfigurasi prompt dapat memiliki lebih dari satu komponen prompt. Dengan demikian, hubungan yang terbentuk antara PromptConfig dan PromptComponent adalah relasi satu-ke-banyak.

Selain itu, tabel PromptExperiment berperan dalam menyimpan data eksperimen yang berkaitan dengan konfigurasi prompt tertentu. Tabel ini juga memiliki atribut config_id sebagai foreign key yang mengacu pada PromptConfig.id. Melalui relasi ini, satu

konfigurasi prompt dapat digunakan pada beberapa eksperimen yang berbeda. Hubungan ini juga membentuk relasi satu-ke-banyak antara PromptConfig dan PromptExperiment.

Tabel	Primary Key (PK)	Foreign Key (FK)	Relasi	Kardinalitas	Keterangan
PromptConfig	Id	-	-	-	Menyimpan data konfigurasi prompt utama
PromptComponent	Id	config_id → PCon.id	PCon→PComp	1:N	Satu konfigurasi prompt memiliki banyak komponen promp
PromptExperiment	id	config_id → PCon.id	PCon→PExp	1:N	Satu konfigurasi prompt dapat digunakan pada banyak eksperimen

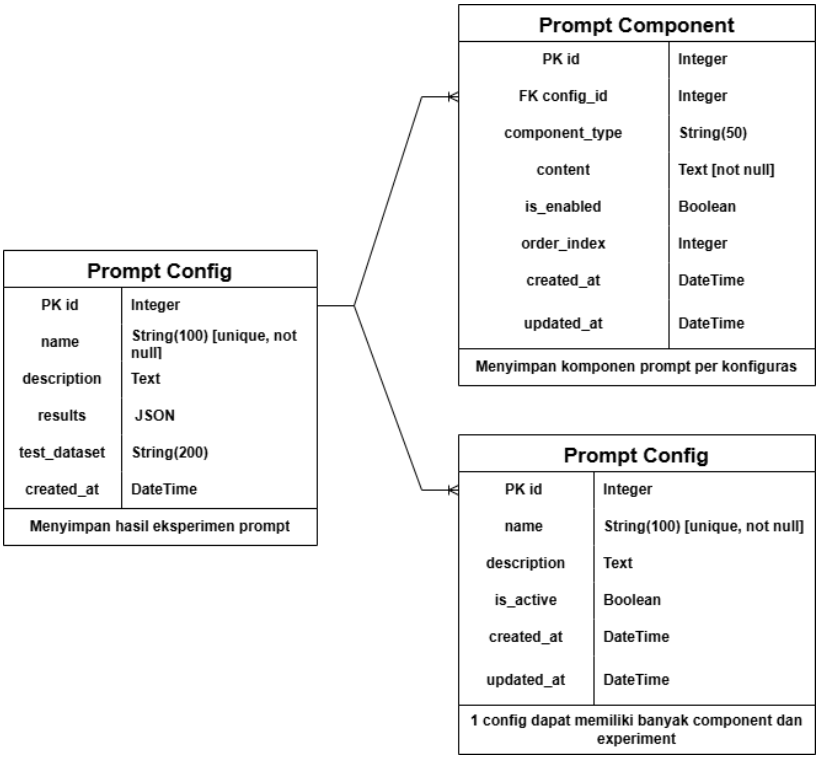

Berdasarkan struktur tersebut, database manajemen prompt dirancang agar pengelolaan konfigurasi dapat dilakukan secara terpusat, sedangkan komponen prompt dan hasil eksperimen dapat dikelompokkan berdasarkan konfigurasi yang digunakan.

Struktur relasi ini mendukung fleksibilitas sistem dalam proses pengaturan prompt, pengujian konfigurasi, dan penyimpanan hasil eksperimen secara terorganisasi.

4.3.6 Ringkasan Hasil Perancangan

Berdasarkan tahapan perancangan dan realisasi sistem yang telah dijelaskan pada subbab sebelumnya, dapat disimpulkan bahwa rancangan sistem klasifikasi teks aduan telah berhasil diimplementasikan dalam bentuk aplikasi web yang terintegrasi. Realisasi tersebut mencakup perancangan arsitektur sistem, antarmuka pengguna, proses klasifikasi, fitur evaluasi, serta manajemen prompt berbasis database. Dengan demikian, seluruh komponen utama yang dirancang pada tahap perancangan telah diwujudkan ke dalam sistem yang dapat dioperasikan secara langsung.

Pada aspek arsitektur, sistem telah direalisasikan dengan pembagian modul yang jelas sehingga alur pemrosesan data dapat berjalan secara sistematis. Pada aspek antarmuka pengguna, sistem menyediakan tampilan yang mendukung proses unggah data, pemilihan model, pemantauan proses klasifikasi, hingga peninjauan hasil. Pada aspek proses klasifikasi, sistem telah mampu memproses data teks melalui tahapan validasi, praproses, inferensi, dan penyimpanan keluaran. Selain itu, fitur evaluasi telah direalisasikan untuk mengukur kualitas hasil klasifikasi secara kuantitatif menggunakan metrik evaluasi utama. Di sisi manajemen prompt, implementasi berbasis database memungkinkan konfigurasi prompt dikelola secara lebih fleksibel dan terstruktur.

Secara keseluruhan, hasil perancangan yang telah direalisasikan menunjukkan bahwa sistem tidak hanya berfungsi pada tingkat implementasi teknis, tetapi juga telah memenuhi kebutuhan fungsional penelitian. Integrasi antar komponen sistem memberikan dukungan terhadap proses klasifikasi teks aduan secara lebih terarah, terukur, dan terdokumentasi. Hasil realisasi ini selanjutnya menjadi landasan untuk pembahasan tahap pengujian, analisis, dan evaluasi kinerja sistem pada subbab atau bab berikutnya.t

4.4. Hasil Uji Coba Dan Pengujian

Tabel isian prompt

Aturan Prompt	Contoh Prompt	Penjelasan
Instruksi Aturan	ATURAN: 1. Prioritaskan KONTEKS UTAMA dari keluhan/pertanyaan, bukan hanya kata kunci yang muncul	Dibuat untuk memberikan penjelasan terkait perintah dan tugas yang diberikan, berupa list peraturan.
Instruksi Larangan	LARANGAN: 1. JANGAN membuat direktorat baru di luar 7 yang tersedia	Berisikan list batasan untuk LLM dalam melakukan klasifikasi, berisikan list larangan.
Intruksi Format Output	Direktorat: [nama_direktorat], Keyword: [keyword_terkait]	Dibuat agar output yang dihasilkan oleh LLM hanya berupa nama dari direktorat, dan keyword yang terkait dengan direktorat tersebut, untuk mengurangi bias dan penggunaan conteks token yang berlebihan.

Keyword list	Direktorat: Aset & Sustainability Keywords: password, parkiran, parkir, gedung, tult, ac	Berisikan daftar keyword untuk direktorat terkait, namun tidak menutup kemungkinan bahwa dalam satu teks terdapat 2 atau lebih keyword dengan direktorat yang berbeda.
Contoh Klasifikasi	Teks: telyu ini kenapa dosen pada nggak mau online sih nyebelin banget → Direktorat: Sumber Daya Manusia, Keyword: dosen	Dibuat untuk memberikan contoh output terkait teks yang ada pada dataset.

Hasil Percobaan

No	Model	Aturan	Hasil

Hasil Klasifikasi LLM			
no	LLM	Prompt	Hasil
1	Qwen3	Instruction : “ATURAN DAN LARANGAN KLASIFIKASI: ATURAN: 1. Prioritaskan KONTEKS UTAMA dari keluhan/pertanyaan, bukan hanya kata kunci yang muncul 2. Jika ada konflik antara beberapa direktorat, pilih yang paling dominan dalam konteks 3. Gunakan "Uncategorized" jika benar-benar tidak ada konteks yang cocok 4. Perhatikan kata-kata sekitar untuk menentukan konteks yang tepat 5. Hindari penggunaan "Akademik" untuk kasus yang lebih spesifik ke direktorat lain LARANGAN: 1. JANGAN membuat direktorat baru di luar 7 yang tersedia 2. JANGAN menambahkan teks lain selain format output yang ditentukan 3. JANGAN mengabaikan konteks hanya karena ada keyword tertentu 4. JANGAN menggunakan "Akademik" sebagai default untuk semua kasus FORMAT OUTPUT WAJIB: Direktorat: [nama_direktorat], Keyword: [keyword_terkait]”	Accuracy 58,5%
		Keywords List : “DAFTAR KEYWORD DIREKTORAT:	

		1. Direktorat: Akademik Primary Keywords: krs, nilai, mata kuliah, sks, prs, tugas akhir, registrasi, libur, sks, ipk, akademik, regis, cumlaude, sidang, yudisium, sk, pa, ta, pembimbing, gdsc 2. Direktorat: Pasca Sarjana dan Advance Learning Keywords: s2, s3, pasca 3. Direktorat: Aset & Sustainability Keywords: password, parkiran, parkir, gedung, tult, ac 4. Direktorat: Keuangan Keywords: bpp, biaya, bayar, ukt, keuangan 5. Direktorat: Sumber Daya Manusia Keywords: dosen, dosbing, dospem, bk, perwalian 6. Direktorat: Pusat Teknologi Informasi Keywords: puti, password, igracias, ktm, lms, toss, tult, wifi, email, akun, web 7. Direktorat: Kemahasiswaan, Pengembangan Karir, Alumni Keywords: magang, msib, kp, wisuda, surat, tak, ktm, pkkmb, beasiswa, eprt, loker, pendaftaran, skl “	
s		Contoh : “CONTOH KLASIFIKASI: Teks: Telyu! Disini ada yg pernah ikut TPA buat daftar S2? itu testnya gimana ya? → Direktorat: Pasca Sarjana dan Advance Learning, Keyword: s2 Teks: Telyu! Kalo misalnya krs udah disetujui doswal dari prodi apa masih bisa otak-atik buat drop/hapus mk yang ada? → Direktorat: Akademik, Keyword: krs Teks: Telyu! Ampun Laak Feb Bikin Surat Pengantar Magang lama banget belum lagi ada batasan tanggal nya → Direktorat: Kemahasiswaan, Pengembangan Karir, Alumni, Keyword: magang Teks: telyu ini kenapa dosen pada nggak mau online sih nyebelin banget → Direktorat: Sumber Daya Manusia, Keyword: dosen Teks: Telyu! nii pihak kampus gaada niat untuk perbaiki parkiran tult kahh??? → Direktorat: Aset & Sustainability, Keyword: parkiran Teks: Telyu! Ada yg pernah ngalamin telat bayar UP3 pas awal ga? Masih bisa bayar kah meskipun lewat tenggat waktu? Butuh info buat mutualku. Makasiiiih → Direktorat: Keuangan, Keyword: bayar	

		Teks: telyu! kan kita bakal ganti semester nah di lms matkul2 smter sebelumnya ntar masih ttp ada atau hilang? klo mau liat lagi matkul2 sebelumnya bisa gak? → Direktorat: Pusat Teknologi Informasi, Keyword: lms “	
Kai 2	Qwen2.5	Instructuin : “Output wajib persis dalam format berikut: Direktorat: [nama_direktorat], Keyword: [keyword_terkait] Hanya gunakan satu direktorat dan satu keyword. DAFTAR DIREKTORAT YANG VALID: - Akademik - Pasca Sarjana dan Advance Learning - Aset & Sustainability - Keuangan - Sumber Daya Manusia - Pusat Teknologi Informasi - Kemahasiswaan, Pengembangan Karir, Alumni”	Accuracy 55,[illegible] %
		Keyword list : “Aturan: 1. Pilih satu direktorat saja. 2. Jika teks membahas aplikasi, login, akun, email, IGRCIAS, LMS, SSO, atau wifi, pilih `Pusat Teknologi Informasi`. 3. Jika teks membahas parkir, gedung, fasilitas fisik, spanduk, atau TULT sebagai lokasi/fasilitas, pilih `Aset & Sustainability`. 4. Jika teks membahas pembayaran, BPP, UKT, biaya, atau tagihan, pilih `Keuangan`. 5. Jika teks membahas magang, KP, loker, karir, alumni, atau pembinaan mahasiswa, pilih `Kemahasiswaan, Pengembangan Karir, Alumni`. 6. Jika teks membahas pendaftaran S2/S3, TPA, program pasca, atau beasiswa pasca, pilih `Pasca Sarjana dan Advance Learning`. 7. Jika teks membahas KRS, SKS, nilai, sidang, yudisium, tugas akhir, registrasi akademik, atau libur akademik, pilih `Akademik`. 8. Jika konteks tidak jelas, pilih `Uncategorized`. 9. Jangan gunakan `Akademik` sebagai jawaban default jika ada direktorat yang lebih spesifik. 10. Jangan menambahkan kalimat, penjelasan, atau informasi tambahan.”	
		Comtoh “Disambiguasi penting: - `KTM` terkait akun, sistem, atau akses aplikasi: `Pusat Teknologi Informasi`. - `KTM` terkait parkir, gerbang, atau kartu fisik di kampus: `Aset & Sustainability`. - `TULT` terkait fasilitas kampus, gedung, atau parkir: `Aset & Sustainability`. - `TULT` terkait tiket digital atau layanan IT: `Pusat Teknologi Informasi`. - `Password` / `akun` / `login` selalu `Pusat Teknologi Informasi`.	

Commented [ba13]: Pakai contoh klasifikasi saja untuk melihat output dari llm nya

		- `Magang`, `KP`, `loker`, `beasiswa`, atau `karir` selalu `Kemahasiswaan, Pengembangan Karir, Alumni`. - `BPP`, `UKT`, `bayar`, atau `pembayaran` selalu `Keuangan`. - Kata akademik formal yang muncul berdampingan dengan kata lain: utamakan direktorat spesifik jika konteksnya lebih ke fasilitas, keuangan, TI, atau kemahasiswaan.”	
3	Llama3	Instruction : “ATURAN DAN LARANGAN KLASIFIKASI: ATURAN: 1. Prioritaskan KONTEKS UTAMA dari keluhan/pertanyaan, bukan hanya kata kunci yang muncul 2. Jika ada konflik antara beberapa direktorat, pilih yang paling dominan dalam konteks 3. Gunakan "Uncategorized" jika benar-benar tidak ada konteks yang cocok 4. Perhatikan kata-kata sekitar untuk menentukan konteks yang tepat 5. Hindari penggunaan "Akademik" untuk kasus yang lebih spesifik ke direktorat lain LARANGAN: 1. JANGAN membuat direktorat baru di luar 7 yang tersedia 2. JANGAN menambahkan teks lain selain format output yang ditentukan 3. JANGAN mengabaikan konteks hanya karena ada keyword tertentu 4. JANGAN menggunakan "Akademik" sebagai default untuk semua kasus FORMAT OUTPUT WAJIB: Direktorat: [nama_direktorat], Keyword: [keyword_terkait]”	Accuracy 61.5%
		Keywords List : “DAFTAR KEYWORD DIREKTORAT: 1. Direktorat: Akademik Primary Keywords: krs, nilai, mata kuliah, sks, prs, tugas akhir, registrasi, libur, sks, ipk, akademik, regis, cumlaude, sidang, yudisium, sk, pa, ta, pembimbing, gdsc 2. Direktorat: Pasca Sarjana dan Advance Learning Keywords: s2, s3, pasca 3. Direktorat: Aset & Sustainability Keywords: password, parkiran, parkir, gedung, tult, ac 4. Direktorat: Keuangan Keywords: bpp, biaya, bayar, ukt, keuangan 5. Direktorat: Sumber Daya Manusia Keywords: dosen, dosbing, dospem, bk, perwalian	

		6. Direktorat: Pusat Teknologi Informasi Keywords: puti, password, igracias, ktm, lms, toss, tult, wifi, email, akun, web 7. Direktorat: Kemahasiswaan, Pengembangan Karir, Alumni Keywords: magang, msib, kp, wisuda, surat, tak, ktm, pkkmb, beasiswa, eprt, loker, pendaftaran, skl “	
		Contoh : “CONTOH KLASIFIKASI: Teks: Telyu! Disini ada yg pernah ikut TPA buat daftar S2? itu testnya gimana ya? → Direktorat: Pasca Sarjana dan Advance Learning, Keyword: s2 Teks: Telyu! Kalo misalnya krs udah disetujui doswal dari prodi apa masih bisa otak-atik buat drop/hapus mk yang ada? → Direktorat: Akademik, Keyword: krs Teks: Telyu! Ampun Laak Feb Bikin Surat Pengantar Magang lama banget belum lagi ada batasan tanggal nya → Direktorat: Kemahasiswaan, Pengembangan Karir, Alumni, Keyword: magang Teks: telyu ini kenapa dosen pada nggak mau online sih nyebelin banget → Direktorat: Sumber Daya Manusia, Keyword: dosen Teks: Telyu! nii pihak kampus gaada niat untuk perbaiki parkiran tult kahh??? → Direktorat: Aset & Sustainability, Keyword: parkiran Teks: Telyu! Ada yg pernah ngalamin telat bayar UP3 pas awal ga? Masih bisa bayar kah meskipun lewat tenggat waktu? Butuh info buat mutualku. Makasiiiih → Direktorat: Keuangan, Keyword: bayar Teks: telyu! kan kita bakal ganti semester nah di lms matkul2 smter sebelumnya ntar masih ttp ada atau hilang? klo mau liat lagi matkul2 sebelumnya bisa gak? → Direktorat: Pusat Teknologi Informasi, Keyword: lms “	
	Qwen 3	Keyword list : “Aturan keputusan: - Gunakan konteks utama, bukan kata tunggal yang kebetulan muncul. - Jika teks tentang nilai, KRS, SKS, semester, libur, sidang, tugas akhir, ijazah, jadwal kuliah -> Akademik. - Jika teks tentang magang, MSIB, MBKM, loker, beasiswa, alumni, KTM hilang/urus KTM -> Kemahasiswaan, Pengembangan Karir, Alumni. - Jika teks tentang S2, S3, TPA, pascasarjana -> Pasca Sarjana dan Advance Learning. - Jika teks tentang parkir, gedung, fasilitas, asrama, logistik, student center, oplib, AC -> Aset & Sustainability.	67,8 %

Commented [ba14]: Pakai contoh klasifikasi saja untuk melihat output dari llm nya

		- Jika teks tentang BPP, UKT, bayar, biaya, tagihan, cicilan -> Keuangan. - Jika teks tentang dosen, dosbing, dospem, doswal, perwalian -> Sumber Daya Manusia. - Jika teks tentang LMS, iGracias, SSO, login, error sistem, email, wifi akses -> Pusat Teknologi Informasi. - Jangan default ke Akademik hanya karena ada kata kampus, semester, atau kuliah. - Jika benar-benar ambigu, pilih Akademik sebagai fallback terakhir. ”	
		Example : “Contoh: Teks: "bagaimana cara daftar msib magang" -> Direktorat: Kemahasiswaan, Pengembangan Karir, Alumni Teks: "nilai kuliah saya berapa" -> Direktorat: Akademik Teks: "kapan bayar bpp semester depan" -> Direktorat: Keuangan Teks: "parkiran tult rusak" -> Direktorat: Aset & Sustainability Teks: "lms tidak bisa login sso" -> Direktorat: Pusat Teknologi Informasi Teks: "dosen saya tidak merespon dosbing" -> Direktorat: Sumber Daya Manusia Teks: "bagaimana syarat pendaftaran s2" -> Direktorat: Pasca Sarjana dan Advance Learning Teks: "ktm saya hilang bagaimana ngurus" -> Direktorat: Kemahasiswaan, Pengembangan Karir, Alumni”	
	Qwen 3	Contoh : “Contoh klasifikasi: Teks: "bagaimana cara daftar msib magang" -> Direktorat: Kemahasiswaan, Pengembangan Karir, Alumni Teks: "ada loker kampus atau lowongan kerja?" -> Direktorat: Kemahasiswaan, Pengembangan Karir, Alumni Teks: "ktm saya hilang, urusnya kemana?" -> Direktorat: Kemahasiswaan, Pengembangan Karir, Alumni Teks: "nilai saya belum keluar" -> Direktorat: Akademik Teks: "kapan libur semester ini?" -> Direktorat: Akademik Teks: "krs masih bisa diubah?" -> Direktorat: Akademik Teks: "tpa s2 daftar dimana?" -> Direktorat: Pasca Sarjana dan Advance Learning Teks: "syarat masuk pascasarjana apa?" -> Direktorat: Pasca Sarjana dan Advance Learning Teks: "parkiran tult penuh terus" -> Direktorat: Aset & Sustainability Teks: "gedung buat ambil ijazah di mana?" -> Direktorat: Aset & Sustainability Teks: "bpp semester depan berapa?" -> Direktorat: Keuangan Teks: "bayar ukt lewat mana?" -> Direktorat: Keuangan Teks: "dosen pembimbing saya tidak respons" -> Direktorat: Sumber Daya Manusia Teks: "doswal saya pindah tugas" -> Direktorat: Sumber Daya Manusia	61,8%

		Teks: "lms error dan tidak bisa login" -> Direktorat: Pusat Teknologi Informasi Teks: "igracias tidak bisa dibuka" -> Direktorat: Pusat Teknologi Informasi Teks: "telyu! aku sidang bulan agustus pgn publish jurnal buat syarat cumlaude. nah aku udh buat jurnalnya tp mingdep baru mau di cek dospem. kira kira keburu ga ya buat dapetin LoA nya?" -> Direktorat: Akademik Teks: "guys aku input TAK tanggal segini kok sampe skrg belum diacc2 yaa? ada yg tau ga kok bisa selama ini? soalnya tumben biasanya paling lama semingguan aja telyu" -> Direktorat: Kemahasiswaan, Pengembangan Karir, Alumni Teks: "telyu! semisal chat tentang keringanan BPP gadibales sama waldos apaboleh langsung ke bagian keuangan kampus?" -> Direktorat: Keuangan Teks: "telyu! ada yg punya kontak PUTI? soalnya aku gabisa login sso karna ganti hp jadi authenticatornya gk nyambung. aku gk bisa langsung dateng ke PUTI nya" -> Direktorat: Pusat Teknologi Informasi Teks: "telyu! Pls air kok nggak nyala nyala ya di asrama gue? capek tau gini terus mana tiap hari caoek tau bolak balik angkat air mau wudhu aja susah" -> Direktorat: Aset & Sustainability Teks: "Telyu! Tips dong buat ngatasin dosen yang kalau ngejelasin materi hitungan atau angka ga ada jeda mau nulis pun ga bakal keburu kalau ngefoto agak susah di pahamin materinya. Apakah kita mahasiswa berhak ngasih masukan tersebut ke dosen yang bersangkutan" -> Direktorat: Sumber Daya Manusia”	

Qwen 3 prompt kosong

Hasil Perbandingan Independen:

Dataset Comparison Results

11.1%	2.6%	11.1%	4.2%
Accuracy	Precision	Recall	F1-Score

Total Data: 18

Comparison Date: 23/04/2026, 16.14.15

Correct Predictions: 2

Incorrect Predictions: 16

Confusion Matrix

Actual \ Predicted	Akademik	Aset & Sustainability	Kemahasiswaan, Pengembangan Karir, Alumni	Keuangan	Pasca Sarjana dan Advance Learning	Pusat Teknologi Informasi	Sumber Daya Manusia	Total
Akademik	1	0	0	0	0	1	1	3
Aset & Sustainability	2	0	0	0	0	0	0	2
Kemahasiswaan, Pengembangan Karir, Alumni	4	0	0	0	0	0	1	5
Keuangan	1	1	0	0	0	0	1	3
Pasca Sarjana dan Advance Learning	0	0	0	0	0	0	1	1
Pusat Teknologi Informasi	1	0	0	0	0	0	2	3
Sumber Daya Manusia	0	0	0	0	0	0	1	1

Qwen 3 prompt ID 1 (lengkap)

Hasil Perbandingan Independen:

Metrik Evaluasi

Accuracy	58.55%
Precision	66.03%
Recall	58.55%
F1-Score	60.17%

Detail

Total Data	1100
Data Sesuai	644
Data Tidak Sesuai	456

Confusion Matrix

Actual \ Predicted	Akademik	Aset & Sustainability	Kemahasiswaan, Pengembangan Karir, Alumni	Keuangan	Pasca Sarjana dan Advance Learning	Pusat Teknologi Informasi	Sumber Daya Manusia	Total Actual
Akademik	232	0	110	1	3	86	7	439
Aset & Sustainability	1	9	8	1	0	8	0	27
Kemahasiswaan, Pengembangan Karir, Alumni	44	9	183	2	4	96	1	339
Keuangan	11	0	3	108	0	5	0	127
Pasca Sarjana dan Advance Learning	0	0	2	0	9	0	0	11
Pusat Teknologi Informasi	14	1	11	1	1	84	0	112
Sumber Daya Manusia	3	0	12	0	1	10	19	45
Total Predicted	305	19	329	113	18	289	27	1100

Qwen 3 prompt ID 8 (tanpa aturan)

Hasil Perbandingan Independen:

Dataset Comparison Results

67.8%	70.4%	67.8%	68.2%
Accuracy	Precision	Recall	F1-Score

Total Data: 1100

Comparison Date: 21/04/2026, 23.23.14

Correct Predictions: 746

Incorrect Predictions: 354

Confusion Matrix

Actual \ Predicted	Akademik	Aset & Sustainability	Kemahasiswaan, Pengembangan Karir, Alumni	Keuangan	Pasca Sarjana dan Advance Learning	Pusat Teknologi Informasi	Sumber Daya Manusia	Total
Akademik	273	1	114	6	1	40	4	439
Aset & Sustainability	0	16	6	0	0	5	0	27
Kemahasiswaan, Pengembangan Karir, Alumni	49	3	238	4	0	41	4	339
Keuangan	7	0	5	112	0	3	0	127
Pasca Sarjana dan Advance Learning	0	0	2	0	9	0	0	11
Pusat Teknologi Informasi	10	1	20	1	0	80	0	112
Sumber Daya Manusia	9	1	8	2	1	6	18	45

Qwen3 prompt example only (hanya contoh output sebagai prompt)

Hasil Perbandingan Independen:

Dataset Comparison Results

61.8%	62.0%	61.8%	61.4%
Accuracy	Precision	Recall	F1-Score

Total Data: 1100

Correct Predictions: 680

Incorrect Predictions: 420

Comparison Date: 23/04/2026, 16.08.41

Confusion Matrix

Actual \ Predicted	Akademik	Aset & Sustainability	Kemahasiswaan, Pengembangan Karir, Alumni	Keuangan	Pasca Sarjana dan Advance Learning	Pusat Teknologi Informasi	Sumber Daya Manusia	Total
Akademik	319	0	88	4	0	22	6	439
Aset & Sustainability	10	12	3	0	0	2	0	27
Kemahasiswaan, Pengembangan Karir, Alumni	142	9	166	3	0	14	5	339
Keuangan	8	0	5	105	0	9	0	127
Pasca Sarjana dan Advance Learning	4	1	1	0	5	0	0	11
Pusat Teknologi Informasi	28	1	25	2	0	56	0	112
Sumber Daya Manusia	20	0	2	2	2	2	17	45

Llama3 prompt ID 6 (lengkap)

Hasil Perbandingan Independen:

Dataset Comparison Results

61.5%	68.1%	61.5%	59.0%
Accuracy	Precision	Recall	F1-Score

Total Data: 1100

Correct Predictions: 676

Incorrect Predictions: 424

Comparison Date: 20/04/2026, 20.11.05

Confusion Matrix

Actual \ Predicted	Akademik	Aset & Sustainability	Kemahasiswaan, Pengembangan Karir, Alumni	Keuangan	Pasca Sarjana dan Advance Learning	Pusat Teknologi Informasi	Sumber Daya Manusia	Total
Akademik	369	1	16	4	1	42	6	439
Aset & Sustainability	12	12	0	0	0	3	0	27
Kemahasiswaan, Pengembangan Karir, Alumni	198	13	95	4	0	24	5	339
Keuangan	6	0	0	106	0	15	0	127
Pasca Sarjana dan Advance Learning	1	0	0	0	10	0	0	11
Pusat Teknologi Informasi	40	1	1	2	0	68	0	112
Sumber Daya Manusia	25	0	0	1	0	3	16	45

Qwen 2 prompt ID 5

Hasil Perbandingan Independen:

Dataset Comparison Results

55.3%	66.1%	55.3%	57.5%
Accuracy	Precision	Recall	F1-Score

Total Data: 1100

Correct Predictions: 608

Incorrect Predictions: 492

Comparison Date: 20/04/2026, 20.14.26

Confusion Matrix

Actual \ Predicted	Akademik	Aset & Sustainability	Kemahasiswaan, Pengembangan Karir, Alumni	Keuangan	Pasca Sarjana dan Advance Learning	Pusat Teknologi Informasi	Sumber Daya Manusia	Uncategorized	Total
Akademik	263	10	39	18	15	44	5	45	439
Aset & Sustainability	2	15	2	0	0	6	0	2	27
Kemahasiswaan, Pengembangan Karir, Alumni	65	21	117	23	16	61	4	32	339
Keuangan	5	0	0	109	1	12	0	0	127
Pasca Sarjana dan Advance Learning	1	0	0	0	10	0	0	0	11
Pusat Teknologi Informasi	15	4	3	0	0	80	0	10	112
Sumber Daya Manusia	14	1	4	3	0	8	14	1	45
Uncategorized	0	0	0	0	0	0	0	0	0

4.5. Hasil Evaluasi

BAB V
ANALISIS DAN PEMBAHASAN

5.1. Verifikasi dan Validasi

DAFTAR PUSTAKA

Abd-Alrazaq, A., AlSaad, R., Alhuwail, D., Ahmed, A., Healy, P. M., Latifi, S., Aziz, S., Damseh, R., Alrazak, S. A., & Sheikh, J. (2023). Large Language Models in Medical Education: Opportunities, Challenges, and Future Directions. *JMIR Medical Education*, *9*. https://doi.org/10.2196/48291

Ahmed, N., Saha, A. K., Al Noman, Md. A., Jim, J. R., Mridha, M. F., & Kabir, M. M. (2024). Deep learning-based natural language processing in human–agent interaction: Applications, advancements and challenges. *Natural Language Processing Journal*, *9*, 100112. https://doi.org/10.1016/j.nlp.2024.100112

Amiruzzaman, S., & Amiruzzaman, M. (2022). Use of Twitter among College Students for Academics: A Mixed-Methods Approach. *Social Sciences*, *11*(9). https://doi.org/10.3390/socsci11090404

Anam, R. K. (2025). *Prompt Engineering and the Effectiveness of Large Language Models in Enhancing Human Productivity*. http://arxiv.org/abs/2507.18638

Beale, R. (2025). *The Revolution Has Arrived: What the Current State of Large Language Models in Education Implies for the Future*. http://arxiv.org/abs/2507.02180

Brown, A., & Wilson, G. (t.t.). *Buy Volume II*. http://www.amyrbrown.ca/.

Chen, B., Zhang, Z., Langrené, N., & Zhu, S. (2025). Unleashing the potential of prompt engineering for large language models. Dalam *Patterns* (Vol. 6, Nomor 6). Cell Press. https://doi.org/10.1016/j.patter.2025.101260

Chen, L., Chen, P., & Lin, Z. (2020). Artificial Intelligence in Education: A Review. *IEEE Access*, *8*, 75264–75278. https://doi.org/10.1109/ACCESS.2020.2988510

Chu, Z., Wang, S., Xie, J., Zhu, T., Yan, Y., Ye, J., Zhong, A., Hu, X., Liang, J., Yu, P. S., Wen, Q., & Learning, A. (t.t.). *LLM Agents for Education: Advances and Applications*.

Danish, M., Amjad, M., Dyussekeyev, K., & Zhumadillayeva, A. (2025). Exploring ChatGPT's Role in Education: An NLP-Based Sentiment and Thematic Study Using Twitter Data. *Procedia Computer Science*, *259*, 959–968. https://doi.org/10.1016/j.procs.2025.04.049

Feng, X., Chen, Z.-Y., Qin, Y., Lin, Y., Chen, † Xu, Liu, Z., & Wen, J.-R. (t.t.). *Large Language Model-based Human-Agent Collaboration for Complex Task Solving*. https://github.com/

Firdaus, R., #2, I. A., & Herdiani, A. (t.t.). *Lexicon-Based Sentiment Analysis of Indonesian Language Student Feedback Evaluation*. https://doi.org/10.34818/indojc.2021.6.1.408

Fong Yee, L., Ai Ling, O., & Jia Wern, K. (2023). *SEARCH Journal of Media and Communication Research A systematic review on communication tactics: Dealing with e-complaints on social media*. https://fslmjournals.taylors.edu.my/search/

Ge, Y., Mei, L., Duan, Z., Li, T., Zheng, Y., Wang, Y., Wang, L., Yao, J., Liu, T., Cai, Y., Bi, B., Guo, F., Guo, J., Liu, S., & Cheng, X. (2025). *A Survey of Vibe Coding with Large Language Models*. http://arxiv.org/abs/2510.12399

Ghaffarzadeh-Esfahani, M., Ghaffarzadeh-Esfahani, M., Salahi-Niri, A., Toreyhi, H., Atf, Z., Mohsenzadeh-Kermani, A., Sarikhani, M., Tajabadi, Z., Shojaeian, F., Bagheri, M. H., Feyzi, A., Tarighat-Payma, M., Gazmeh, N., Heydari, F., Afshar, H., Allahgholipour, A., Alimardani, F., Salehi, A., Asadimanesh, N., … Safavi-Naini, S. A. A. (2025). Large language models versus classical machine learning performance in COVID-19 mortality prediction using high-dimensional tabular data. *Scientific Reports*, *15*(1). https://doi.org/10.1038/s41598-025-26705-7

Hafiz, M., Ibrahim, B., Dzulkarnain, A., & Rausanfita, A. (2025). BULLETIN OF COMPUTER SCIENCE RESEARCH Penggunaan Metode Naïve Bayes untuk Klasifikasi Topik Tweet Bidang dan Non-Bidang Rektorat Telkom University pada Akun Telyufess. *Media Online)*, *5*(5), 876–885. https://doi.org/10.47065/bulletincsr.v5i5.705

Hajikhani, A., & Cole, C. (2024). A critical review of large language models: Sensitivity, bias, and the path toward specialized AI. *Quantitative Science Studies*, *5*(3), 736–756. https://doi.org/10.1162/qss_a_00310

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., … Oliphant, T. E. (2020). Array programming with NumPy. Dalam *Nature* (Vol. 585, Nomor 7825, hlm. 357–362). Nature Research. https://doi.org/10.1038/s41586-020-2649-2

Hino, A., & Fahey, R. A. (2019). Representing the Twittersphere: Archiving a representative sample of Twitter data under resource constraints. *International Journal of Information Management*, *48*, 175–184. https://doi.org/10.1016/j.ijinfomgt.2019.01.019

Kallstenius, T., Capusan, A. J., Andersson, G., & Williamson, A. (2025). Comparing traditional natural language processing and large language models for mental health status classification: a multi-model evaluation. *Scientific Reports*, *15*(1). https://doi.org/10.1038/s41598-025-08031-0

Kostina, A., Dikaiakos, M. D., Stefanidis, D., & Pallis, G. (2025). *Large Language Models For Text Classification: Case Study And Comprehensive Review*. http://arxiv.org/abs/2501.08457

Lin, T., Wang, Y., Liu, X., & Qiu, X. (2022). A survey of transformers. *AI Open*, *3*, 111–132. https://doi.org/10.1016/j.aiopen.2022.10.001

Marvin, G., Hellen, N., Jjingo, D., & Nakatumba-Nabende, J. (2024). *Prompt Engineering in Large Language Models* (hlm. 387–402). https://doi.org/10.1007/978-981-99-7962-2_30

Mei, L., Yao, J., Ge, Y., Wang, Y., Bi, B., Cai, Y., Liu, J., Li, M., Li, Z.-Z., Zhang, D., Zhou, C., Mao, J., Xia, T., Guo, J., & Liu, S. (2025). *A Survey of Context Engineering for Large Language Models*. http://arxiv.org/abs/2507.13334

Minaee, S., Mikolov, T., Nikzad, N., Chenaghlu, M., Socher, R., Amatriain, X., & Gao, J. (2025). *Large Language Models: A Survey*. http://arxiv.org/abs/2402.06196

openpyxl. (t.t.).

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury Google, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Xamla, A. K., Yang, E., Devito, Z., Raison Nabla, M., Tejani, A., Chilamkurthy, S., Ai, Q., Steiner, B., … Chintala, S. (2019). *PyTorch: An Imperative Style, High-Performance Deep Learning Library*.

Pedregosa FABIANPEDREGOSA, F., Michel, V., Grisel OLIVIERGRISEL, O., Blondel, M., Prettenhofer, P., Weiss, R., Vanderplas, J., Cournapeau, D., Pedregosa, F., Varoquaux, G., Gramfort, A., Thirion, B., Grisel, O., Dubourg, V., Passos, A., Brucher, M., Perrot andÉdouardand, M., Duchesnay, andÉdouard, & Duchesnay EDOUARDDUCHESNAY, Fré. (2011). Scikit-learn: Machine Learning in Python Gaël Varoquaux Bertrand Thirion Vincent Dubourg Alexandre Passos PEDREGOSA, VAROQUAUX, GRAMFORT ET AL. Matthieu Perrot. Dalam *Journal of Machine Learning Research* (Vol. 12). http://scikit-learn.sourceforge.net.

Peffers, K., Tuunanen, T., Gengler, C. E., Rossi, M., Hui, W., Virtanen, V., & Bragge, J. (t.t.). *THE DESIGN SCIENCE RESEARCH PROCESS: A MODEL FOR PRODUCING AND PRESENTING INFORMATION SYSTEMS RESEARCH Corresponding Author*.

Plaat, A., Wong, A., Verberne, S., Broekens, J., Van Stein, N., & B썬ck, T. (2025). Multi-step Reasoning with Large Language Models, A Survey. *ACM Computing Surveys*. https://doi.org/10.1145/3774896

Ronanki, K., Arvidsson, S., & Axell, J. (2025). *Prompt Engineering Guidelines for Using Large Language Models in Requirements Engineering*. http://arxiv.org/abs/2507.03405

Sahoo, P., Singh, A. K., Saha, S., Jain, V., Mondal, S., & Chadha, A. (2025). *A Systematic Survey of Prompt Engineering in Large Language Models: Techniques and Applications*. http://arxiv.org/abs/2402.07927

Shahzad, T., Mazhar, T., Tariq, M. U., Ahmad, W., Ouahada, K., & Hamam, H. (2025). A comprehensive review of large language models: issues and solutions in learning environments. Dalam *Discover Sustainability* (Vol. 6, Nomor 1). Springer Nature. https://doi.org/10.1007/s43621-025-00815-8

Shao, P., Wang, J., Zhou, W., Wu, X., & Xu, L. (2025). When Large Language Models Meet Law: Dual-Lens Taxonomy, Technical Advances, and Ethical Governance. Dalam *ACM Computing Surveys* (Vol. 37, Nomor 4). https://doi.org/XXXXXXX.XXXXXXX

Sharma, R., Mehta, M., & Raina, S. T. (2025). *RLHF: A comprehensive Survey for Cultural, Multimodal and Low Latency Alignment Methods*. http://arxiv.org/abs/2511.03939

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing and Management*, *45*(4), 427–437. https://doi.org/10.1016/j.ipm.2009.03.002

The state of AI in 2025 Agents, innovation, and transformation. (2025).

Vajjala, S., Alhafni, B., Bannò, S., Maurya, K. K., & Kochmar, E. (2025). *Opportunities and Challenges of LLMs in Education: An NLP Perspective*. http://arxiv.org/abs/2507.22753

Vaswani, A., Brain, G., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (t.t.). *Attention Is All You Need*.

Vatsal, S., Dubey, H., & Singh, A. (2025). *Multilingual Prompt Engineering in Large Language Models: A Survey Across NLP Tasks*. http://arxiv.org/abs/2505.11665

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., Von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., … Rush, A. M. (t.t.). *Transformers: State-of-the-Art Natural Language Processing*. https://github.com/huggingface/

Zdravkova, K., & Ilijoski, B. (2025). The impact of large language models on computer science student writing. *International Journal of Educational Technology in Higher Education*, *22*(1). https://doi.org/10.1186/s41239-025-00525-1

Zhang, D., Yu, Y., Dong, J., Li, C., Su, D., Chu, C., & Yu, D. (2024). *MM-LLMs: Recent Advances in MultiModal Large Language Models*. http://arxiv.org/abs/2401.13601

LAMPIRAN